Cvičení 5 - B2M31AEDA

Nahrání dat

Dejte si pozor na to, aby jste byli v MATLABu ve složce, kde máte umístěn soubor s daty (data.csv), nebo máte složku, ve které je soubor s daty, přidanou do cesty MATLABu (Matlab Path).

```
T = readtable('data.csv','ReadVariableNames',true);
```

1. Vizualizace dat

Vizualizaci proveďte s důrazem na čitelnost a přehlednost. Cílem je vidět co nejlépe případné rozdíly mezi skupinami. Doporučujeme využít zobrazení pomocí `boxplot` či `boxchart` a rozvržení grafů pomocí funkce `tiledlayout`.

Vizualizaci proveďte pro všechny 4 měřené akustické parametry: RI, DVA, MPT a stdF0.

```
% Váš kód pro vizualizaci
% help tiledlayout
% help boxplot
% help boxchart


tiledlayout("flow")
nexttile
boxchart([T{T.group == "HC", "RI"} T{T.group == "PD", "RI"} T{T.group ==
"HD", "RI"}])
set(gca, 'XTickLabel', {'HC', 'PD', 'HD'})
title('a) Rhythm acceleration'); ylabel('RI (%)')

nexttile
boxchart([T{T.group == "HC", "DVA"} T{T.group == "PD", "DVA"} T{T.group
== "HD", "DVA"}])
ylim([0 5])
set(gca, 'XTickLabel', {'HC', 'PD', 'HD'})

title('b) Degree of vocal arrest'); ylabel('DVA (%)')

nexttile
boxchart([T{T.group == "HC", "MPT"} T{T.group == "PD", "MPT"} T{T.group
== "HD", "MPT"}])
set(gca, 'XTickLabel', {'HC', 'PD', 'HD'})
title('c) Maximum phonation time'); ylabel('MPT (s)')

nexttile
boxchart([T{T.group == "HC", "stdF0"} T{T.group == "PD", "stdF0"}
T{T.group == "HD", "stdF0"}])
set(gca, 'XTickLabel', {'HC', 'PD', 'HD'})
title('d) Standard deviation of fundamental frequency '); ylabel('stdF0
(Hz)')
```

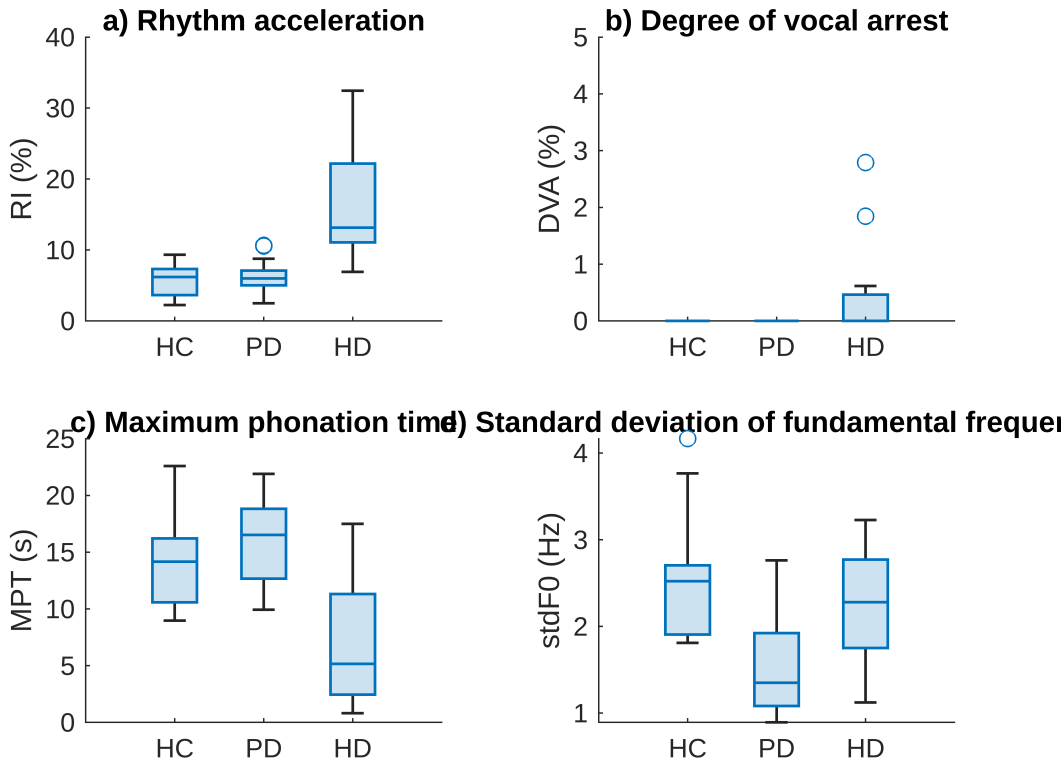

Otázky:

- Pohledem vyhodnoťte jestli jednotlivé skupiny vykazují normální rozdělení (respektive spíše pokud nějaká skupina vykazuje **významné odchylky od normálního rozdělení**) a zdali je mezi skupinami pro každý z parametrů vidět nějaký **efekt** (silný/slabý, či z hlediska pacienta pozitivní/negativní, …).

RI - normální rozdělení, silný efekt pro HD, to je ale silně skewed.

DVA - není normální, slabý efekt pro HD, má občas nenulovou hodnotu

MPT - normální rozdělení silný efekt pro HD, to je ale silně skewed

stdF0 - normální rozdělení, silný efekt pro PD

2. Ověření podmínek pro ANOVA

2a Ověření Normality vstupních dat

- Vyberte vhodný test, viz předešlé cvičení a přednáška.
- Není třeba vypisovat hypotézy, pouze si dejte pozor – u jednotlivých testů se liší (viz např. rozdíl mezi `kstest` a `swtest`).
- Výsledky testu korektně reportujte.

```
% Váš kód pro ověření normality
alpha = 0.05;
```

```
res = table('Size',[0, 4], 'VariableTypes', ["string", "string",
"string", "logical"], 'VariableNames', ["Group", "Data", "SW test
report", "Is normal"]);

for group=["HC", "PD", "HD"]
    for data=["RI", "DVA", "MPT", "stdF0"]
        [H, pValue, SWstatistic] = swtest(T{T.group == group, data},
alpha);
        res = [res; {group, data, sprintf('swtest(W = %.2f, p =
%.2f)',SWstatistic, pValue), ~H}];
    end
end

disp(res)
```

Group	Data	SW test report	Is normal
"HC"	"RI"	"swtest(W = 0.95, p = 0.51)"	true
"HC"	"DVA"	"swtest(W = NaN, p = NaN)"	true
"HC"	"MPT"	"swtest(W = 0.91, p = 0.16)"	true
"HC"	"stdF0"	"swtest(W = 0.87, p = 0.03)"	false
"PD"	"RI"	"swtest(W = 0.92, p = 0.21)"	true
"PD"	"DVA"	"swtest(W = NaN, p = NaN)"	true
"PD"	"MPT"	"swtest(W = 0.95, p = 0.53)"	true
"PD"	"stdF0"	"swtest(W = 0.90, p = 0.11)"	true
"HD"	"RI"	"swtest(W = 0.86, p = 0.02)"	false
"HD"	"DVA"	"swtest(W = 0.36, p = 0.00)"	false
"HD"	"MPT"	"swtest(W = 0.86, p = 0.03)"	false
"HD"	"stdF0"	"swtest(W = 0.94, p = 0.42)"	true

Zde vidíme, že používat DVA je úplně zbytečné, jelikož ve 2/3 skupin nemáme data

2b Ověření homogenity rozptylů

- **BUĎ:** Korektním způsobem argumentujte, proč lze požadavek na homogenitu rozptylů považovat za splněný i bez provádění testů. *Toto odůvodnění zapište slovy.*
- **NEBO:** Otestujte rovnost rozptylů pomocí vhodné analýzy – Bartlettova nebo Levenova testu. Výsledek testu korektně reportujte a interpretujte. Nápověda: funkce `vartestn`.

```
% Váš kód pro ověření homoskedasticity, pokud budete ověřovat pomocí testu

for data=["RI", "MPT", "stdF0"]
    fprintf("variable: %s", data)
    p = vartestn(T{:, data}, T.group, "TestType","LeveneAbsolute");

end
```

```
variable: RI
```

Group Summary Table

Group	Count	Mean	Std Dev
HC	15	5.751	2.30735
PD	15	6.3755	2.21245
HD	15	17.1335	8.39618
Pooled	45	9.7533	5.18699

Levene's statistic (absolute)	15.1761
Degrees of freedom	2, 42
p-value	0

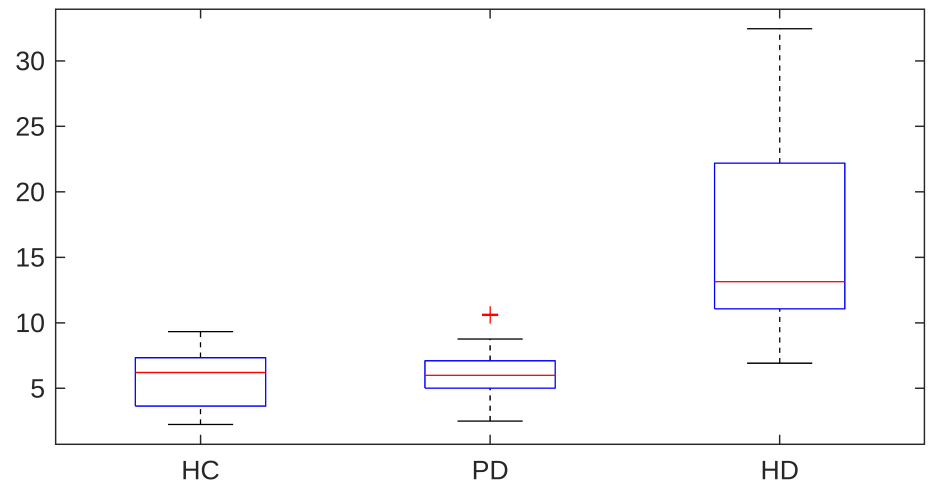

variable: MPT

Group Summary Table

Group	Count	Mean	Std Dev
HC	15	14.1314	4.1412
PD	15	16.0127	3.70727
HD	15	6.6603	5.49302
Pooled	45	12.2681	4.51171

Levene's statistic (absolute)	1.32613
Degrees of freedom	2, 42
p-value	0.27639

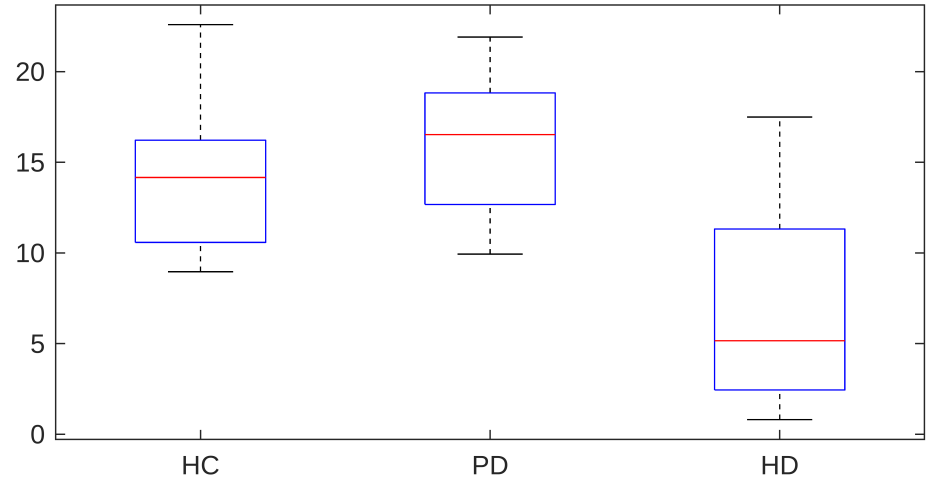

variable: stdF0

Group Summary Table

Group	Count	Mean	Std Dev
HC	15	2.58752	0.72894
PD	15	1.51255	0.55991
HD	15	2.20745	0.67762
Pooled	45	2.10251	0.6593

Levene's statistic (absolute)	0.24407
Degrees of freedom	2, 42
p-value	0.78454

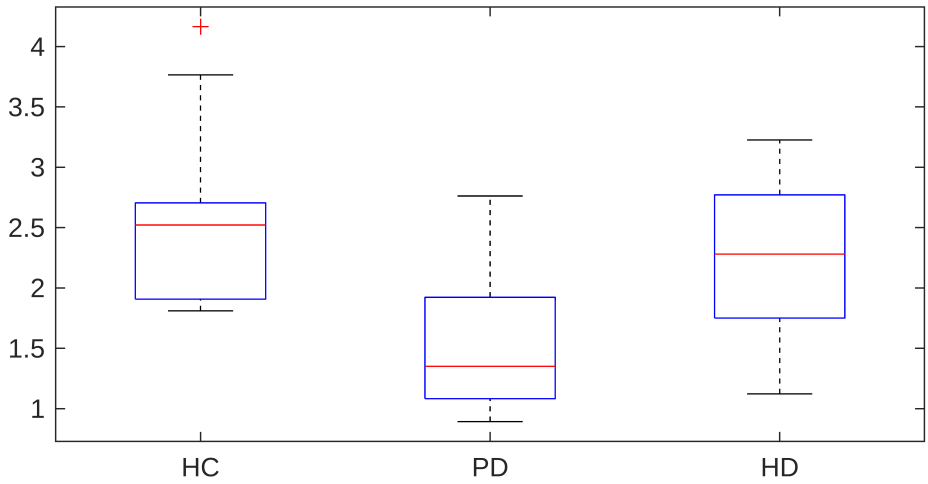

Z testů vychází, že pouze MPT a stdF0 jsou homoskedasticitní.

3. Úloha

Chtěli bychom dokázat, že lze rozlišit zdravé lidi (HC), pacienty s PD a pacienty s HD jen na základě nahrávek řečových testů, a případně i potvrdit, že změny v akustických parametrech úzce souvisí s celkovým klinickým hodnocením stavu pacienta.

Použijte informace, které jste získali v předchozích částech, pro výběr vhodných testů a následnou interpretaci. Odpovězte na následující otázky:

1. *Lze mezi sebou statisticky významně rozlišit skupiny HC, PD a HD pomocí parametrů RI, MPT, DVA nebo stdF0? V této části hledáte jen odpověď* ***ano či ne pomocí vhodného testu.***
2. *Pokud jste zjistili, že pomocí nějakého parametru lze od sebe skupiny odlišit,* ***jaké dvojice skupin vykazují mezi sebou statisticky významné rozdíly****?*
3. *Jaký je* ***vztah mezi zrychlováním řeči*** *(parametr RI****) a klinickým hodnocením lékařem*** *(hodnoty z dotazníků UPDRS a UHDRS)? Odpovídá horší schopnost udržet tempo řeči vyššímu motorickému postižení, hodnocenému lékařem?*

- Výběr statistických testů **odůvodněte**.
- Pro opakované testy stačí zapsat testové hypotézy **jen jednou**.
- Reportujte výsledky testů **korektně** (využijte přednášku).
- Výsledky testů **interpretujte** s ohledem na předešlá rozhodnutí o normalitě, homoskedasticitě, výběru testu a výběru post-hoc metody.

1)

H0: Měřené skupiny mají stejný průměr.

H1: Mezi měřenými skupinami je signifikantní rozdíl.

```
% Váš kód
for data=["RI", "MPT", "stdF0"]
    fprintf("variable: %s", data)
    [p,tbl,stats] = anova1(T{:, data}, T.group);
end
```

```
variable: RI
```

ANOVA Table

Source	SS	df	MS	F	Prob>F
Groups	1228.41	2	614.207	22.83	1.94825e-07
Error	1130	42	26.905		
Total	2358.42	44			

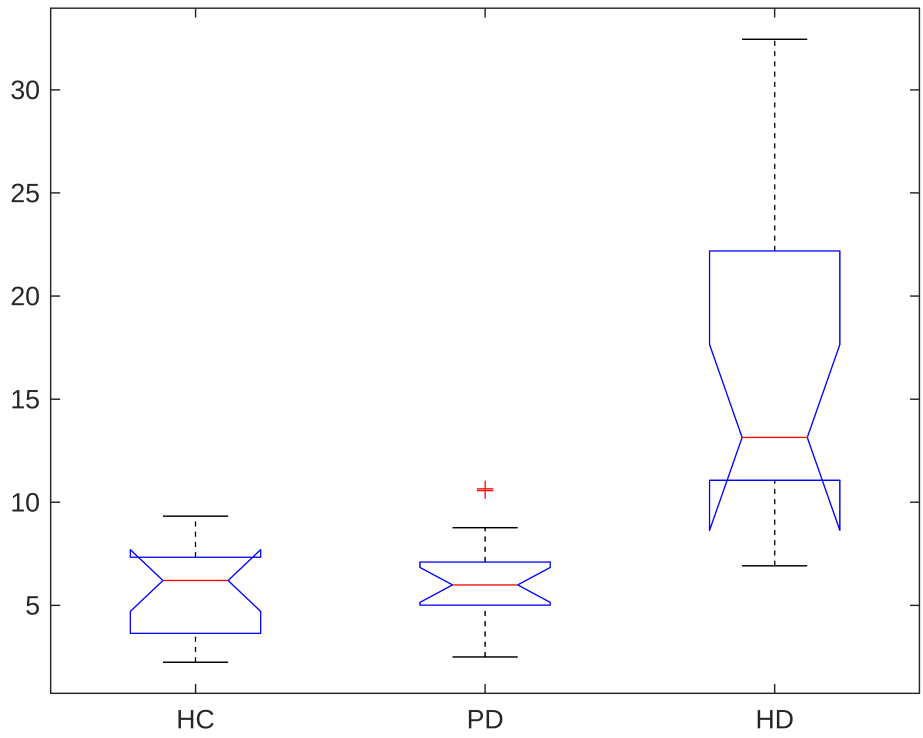

variable: MPT

ANOVA Table

Source	SS	df	MS	F	Prob>F
Groups	734.11	2	367.057	18.03	2.22178e-06
Error	854.93	42	20.356		
Total	1589.05	44			

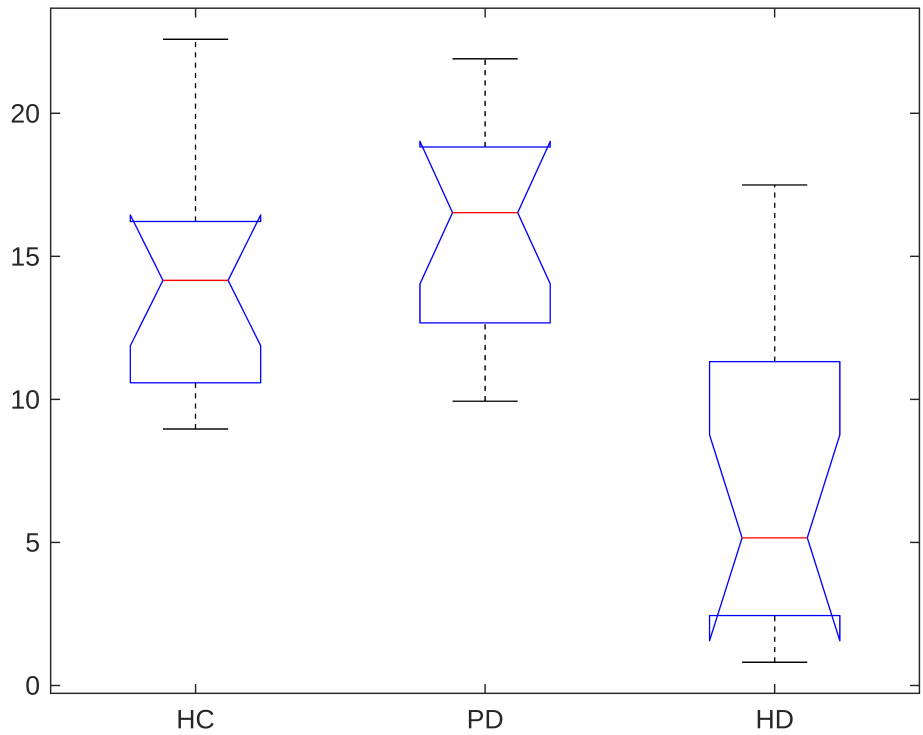

variable: stdF0

ANOVA Table

Source	SS	df	MS	F	Prob>F
Groups	8.9145	2	4.45724	10.25	0.0002
Error	18.2563	42	0.43467		
Total	27.1708	44			

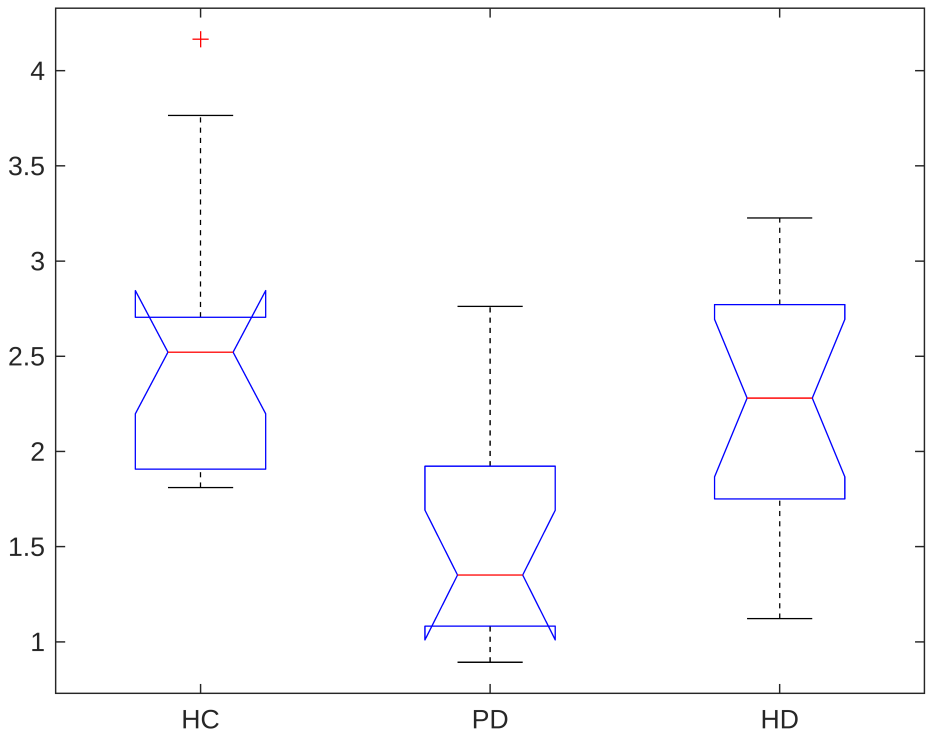

U všech parametrů zamítáme H0 ve prospěch H1.

2)

H0: Rozdíl průměrů daných dvou měřených skupin není signifikantní.

```
for data=["RI", "MPT", "stdF0"]
    fprintf("variable: %s\n", data)
    [~,~,stats] = anova1(T{:, data}, T.group, "off");
    [results, means, ~, gnames] = multcompare(stats, Display="off");
    tbl = array2table([results,means],"VariableNames", ...
    ["Group A","Group B","Lower Limit","A-B","Upper Limit","P-
value","Mean","Standard Error"]);
    tbl.("Group A")=gnames(tbl.("Group A"));
    tbl.("Group B")=gnames(tbl.("Group B"));
    disp(tbl)
end
```

```
variable: RI
    Group A    Group B    Lower Limit      A-B       Upper Limit     P-value       Mean     Standard Er
    _______    _______    ___________    ________    ___________    __________    ______    ___________

    {'HC'}     {'PD'}        -5.226      -0.62453       3.977         0.94191      5.751       1.3393
    {'HC'}     {'HD'}       -15.984       -11.382      -6.7809      1.1405e-06    6.3755       1.3393
    {'PD'}     {'HD'}       -15.359       -10.758      -6.1564      3.3873e-06    17.133       1.3393
variable: MPT
    Group A    Group B    Lower Limit      A-B      Upper Limit     P-value       Mean     Standard Err
    _______    _______    ___________    _______    ___________    __________    ______    ___________

    {'HC'}     {'PD'}       -5.8838      -1.8813      2.1212          0.4941     14.131       1.1649
    {'HC'}     {'HD'}        3.4686       7.4711      11.474       0.00013819    16.013       1.1649
    {'PD'}     {'HD'}        5.3499       9.3524      13.355       3.4215e-06    6.6603       1.1649
variable: stdF0
```

Group A	Group B	Lower Limit	A-B	Upper Limit	P-value	Mean	Standard Err
{'HC'}	{'PD'}	0.49009	1.075	1.6598	0.00017209	2.5875	0.17023
{'HC'}	{'HD'}	-0.20481	0.38007	0.96495	0.26592	1.5125	0.17023
{'PD'}	{'HD'}	-1.2798	-0.6949	-0.11002	0.016532	2.2075	0.17023

U proměnných *RI* a *MPT* je skupina HD signifaktně rozdílná od ostatních

U proměnné stdF0 je signifikantně rozdílná skupina PD

3)

H0: průměrný rozdíl RI a UPDRS (UHDRS) je nulový.

```
[~, p, ~, stats] = ttest(T{T.group == "PD", "UPDRS_III"}, T{T.group ==
"PD", "RI"});
fprintf("UPDRS_III\nt(%.0f)=%.4f, p = %.4f", stats.df, stats.tstat, p)
```

```
UPDRS_III
t(14)=7.5219, p = 0.0000
```

```
[~, p, ~, stats] = ttest(T{T.group == "HD", "UHDRS"}, T{T.group == "HD",
"RI"});
fprintf("UHDRS\nt(%.0f)=%.4f, p = %.4f", stats.df, stats.tstat, p)
```

```
UHDRS
t(14)=1.1419, p = 0.2726
```

H0 zamítáme pro UPDRS III, tedy zde měřený parametr RI odpovídá klinickému hodnocemí u pacientů s PD. Naopak u pacientů s HD RI odpovídá klinickému hodnocení.