Cvičení 6 - B2M31AEDA

Nahrání dat

Důležité! V dnešním cvičení naleznete na Moodle ke stažení dva data sety, **`data.csv`** a **`large_dataset.csv`**. Předtím, než přistoupíte k načítání dat do Matlabu (klasicky pomocí funkce `readtable`, viz předešlá cvičení), musíte se rozhodnout, který z těchto dvou datasetu použijete.

ČTĚTE POZORNĚ ZADÁNÍ!!!

```
large = true;
if large
    T = readtable('large_dataset.csv','ReadVariableNames',true);
else
    T = readtable('data.csv','ReadVariableNames',true);
end
```

1. Estimace potřebné velikosti vzorku

V této části potřebujete program GPower, volně ke stažení pomocí odkazu v zadání. V zadání se také nachází na konci PDF návod na použití.

Pečlivě čtěte zadání, v této části je možné udělat mnoho malých chyb.

1. Nejprve si musíte přečíst otázky na konci zadání (v 3. části), na které budete chtít odpovídat.
2. Vyberte statistický test, který na jejich zodpovězení použijete. Správně vyhodnoťte normalitu parametrů (viz zadání).
3. Vypočítejte pomocí GPower potřebnou velikost vzorku.

Otázky:

- Zapište jaké testy použijete pro zodpovězení otázek z části 3.
- Zapište vypočtené minimální potřebné velikosti vzorku pro jednotlivé testy.
- Zaznamenejte jaké datasety jste se rozhodli použít případně jaké parametry jste se rozhodli vyřadit.

Vaše odpovědi a výsledky:

Zapište jaké testy použijete pro zodpovězení otázek z části 3.

1. otázka Ttest2 + korekce
2. otázka korelace + korekce

Zapište vypočtené minimální potřebné velikosti vzorku pro jednotlivé testy.

1)

DDKG = 454

DDKR = 20

stdF0 = 384

jitter = 54

2)

Speech = 36

Zaznamenejte jaké datasety jste se rozhodli použít případně jaké parametry jste se rozhodli vyřadit.

Large dataset, vyřazuji DDKGa stdF0

2. Vizualizace vybraných dat

Skupiny dat vybrané pro zodpovězení otázek z části 3 vhodně vizualizujte. Použijte zobrazení, na kterém bude nejvíce zřetelný efekt mezi skupinami.

```
% Váš kód pro vizualizaci
function d = cohenD(data1, data2)
    n1 = length(data1); n2 = length(data2);
    s1 = std(data1); s2 = std(data2);
    mu1 = mean(data1); mu2 = mean(data2);

    sP = sqrt(((n1 - 1)*(s1^2) + (n2 - 1)*(s2^2))/(n1+n2+2));
    d = (mu1 - mu2)/sP;
end

tl = tiledlayout("flow");
title(tl, "Data visualization")
ax1 = nexttile;
data1 = T{T.group == "HC", "DDKR"};
data2 = T{T.group == "EP", "DDKR"};
if length(data1) > length(data2)
    data2 = [data2; NaN(length(data1) - length(data2), 1)];
elseif length(data1) < length(data2)
    data1 = [data1; NaN(length(data2) - length(data1), 1)];
end

boxchart([data1, data2])
set(gca, 'XTickLabel', {'HC', 'EP'})
title('a) DDK rate'); ylabel('DDKR (syll/s)')
pbaspect(ax1,[1 1 1]);
d1 = cohenD(T{T.group == "HC", "DDKR"}, T{T.group == "EP", "DDKR"});
subtitle(sprintf("d = %.2f", d1))

ax2=nexttile;
data1 = T{T.group == "HC", "jitter"};
data2 = T{T.group == "EP", "jitter"};
if length(data1) > length(data2)
    data2 = [data2; NaN(length(data1) - length(data2), 1)];
elseif length(data1) < length(data2)
    data1 = [data1; NaN(length(data2) - length(data1), 1)];
end
boxchart([data1 data2])
set(gca, 'XTickLabel', {'HC', 'EP'})
title('b) Jitter'); ylabel('jitter (%)')
pbaspect(ax2,[1 1 1]);
d2 = cohenD(T{T.group == "EP", "jitter"}, T{T.group == "HC", "jitter"});
subtitle(sprintf("d = %.2f", d2))
```

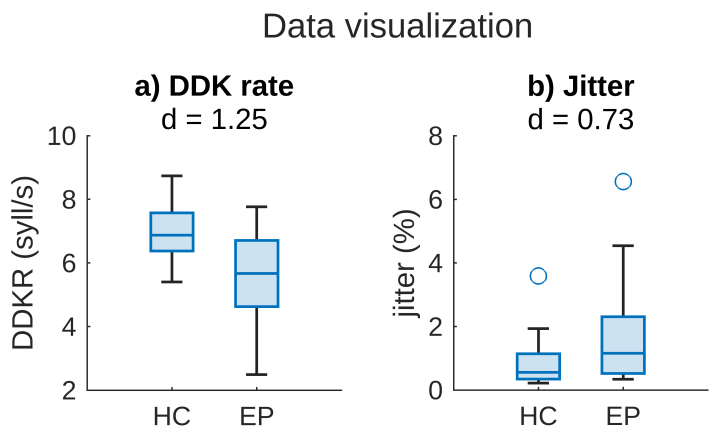

- Slovně zhodnoťte (vizuálním odhadem), zdali je mezi skupinami vidět nějaký efekt skupin (size effect).
- Vypočítejte velikost efektu skupin pomocí Cohenova d a podle jeho velikosti uveďte, jak velký tento efekt je.

Vaše odpovědi a výsledky:

U obou je vidět rozdíl, u DDKR výraznější. Toto potvrzuje i Cohenovo d.

DDKR má velmi vysoký sizeeffect, Jitter ho má významný

3. Úloha

K následujícím otázkám navrhněte hypotézy, vyberte vhodné testy, nastavte hladinu statistické významnosti korigovanou pro ošetření chyby I. typu a korektně reportujte svoje výsledky do Moodle. **Mějte na paměti, že oproti předešlým cvičením, zde budete mít jednu hypotézu na každou z otázek, a pod touto hypotézou provedete určitý počet testů.**

- *Vykazuje skupina EP rozdíly oproti skupině zdravých lidí z pohledu nějakého z příznaků DDKG, DDKR, stdF0 nebo jitter?*
- *Odráží příznak DDKG, DDKR, stdF0 nebo jitter motorické zhodnocení pomocí skóre NNIPPS? Vyberte si* **jednu položku** *z dotazníku NNIPPS, pro kterou vztah vyšetříte.*

```
% Váš kód
% 1
no_test = 2;
alpha = 0.05;
bonferroni_alpha = alpha / no_test;

h = zeros(1,no_test);
p = zeros(1,no_test);
ci = zeros(1,no_test);
stats = struct('tstat', {}, 'df', {}, 'sd', {});

r1 = [T{T.group == "HC", "DDKR"}, T{T.group == "HC", "jitter"}];
r2 = [T{T.group == "EP", "DDKR"}, T{T.group == "EP", "jitter"}];
```

```
for i=1:no_test
    [h(i), p(i), ci(i,:), stats(i)] = ttest2(r1(:,i), r2(:,i));
end

h = p < bonferroni_alpha;

% 2
no_test = 2;
alpha = 0.05;
bonferroni_alpha = alpha / no_test;

rho = zeros(1,no_test);
p = zeros(1,no_test);

r1 = [T{T.group == "EP", "DDKR"}, T{T.group == "EP", "jitter"}];
r2 = T{T.group == "EP", "Speech"};

for i=1:no_test
    [rho(i), p(i)] = corr(r1(:,i), r2);
end
h = p < bonferroni_alpha;
```

Hypotézy, reporty:

H0: skupina EP nevykazuje rozdíl oproti skupině HC z příznaků (DDKR, Jitter)

alpha = 0.05

t_DDKR(51) = 4.3752, p = .0000601

t_jitter(51) = -2.5539, p = .0137

Po korekci zamítáme obě H0 ve prospěch alternativních hypotéz.

====

H0: korelace skore NNIPPS a parametru (DDKR, Jitter) je nulová.

alpha = 0.05

r_DDKR(26) = -0.6501, p = .00018, 1-β = .955

r_jitter(26) = .4188, p = 0.0266, 1-β = .507

Po korekci zamítáme první test a nezamítáme druhý. Tedy DDKR odráží položku Speech testu NNIPPS.