Cvičení 8 - B2M31AEDA

Nahrání dat

Popis dat: Pracovní data jsou uložena v souboru data.csv, který je k dispozici ke stažení na Moodle stránce tohoto předmětu, ve složce příslušného cvičení. Pro načtení dat do Matlabu využijte funkce `readtable`.

```
T = readtable('data.csv','ReadVariableNames',true);
```

1. Vyhledání lineárních vztahů mezi parametry

- Pomocí korelační analýzy najděte mezi možnými dvojicemi nezávislých parametrů takové, které budou vykazovat významný lineární vztah.
- Nezávislá dvojice například **není** celkové skóre dotazníku UPDRS a skóre z nějaké z jeho podsekcí.
- Hranici pro určení toho, který vztah je významný, a který ne, určete buď na základě vámi zvolené hraniční hodnoty korelačního koeficientu nebo pomocí statistické významnosti korelace vůči vybrané úrovni alfa.

Uveďte, jak jste nastavili hranici významnosti a korektně reportujte výsledky korelační analýzy pro nejvýznamnější dvojice.

```
% Váš kód pro korelační analýzu
types = {'DDKR', 'VOT', 'stdPWR', 'stdF0', 'jitter', 'PPT', 'AmpDec', 'VFT',
'UPDRS_III', 'UPDRS_III_axial', 'UPDRS_III_bradykinesia' , 'L_dopa_equivalent'};
[r, p] = corrcoef(T{:, types});
compare = [0    0    1    1    1    1    1    1    1    1    1    1;
           0    0    1    1    1    1    1    1    1    1    1    1;
           1    1    0    0    0    1    1    1    1    1    1    1;
           1    1    0    0    0    1    1    1    1    1    1    1;
           1    1    0    0    0    1    1    1    1    1    1    1;
           1    1    1    1    1    0    1    1    1    1    1    1;
           1    1    1    1    1    1    0    1    1    1    1    1;
           1    1    1    1    1    1    1    0    1    1    1    1;
           1    1    1    1    1    1    1    1    0    0    0    1;
           1    1    1    1    1    1    1    1    0    0    0    1;
           1    1    1    1    1    1    1    1    0    0    0    1;
           1    1    1    1    1    1    1    1    1    1    1    0];

compare(compare == 0) = NaN;

res = p .* compare;
h = heatmap(res);
h.YDisplayLabels = regexprep(types, '_', '\\_');
h.XDisplayLabels = regexprep(types, '_', '\\_');
title("P values heatmap")
```

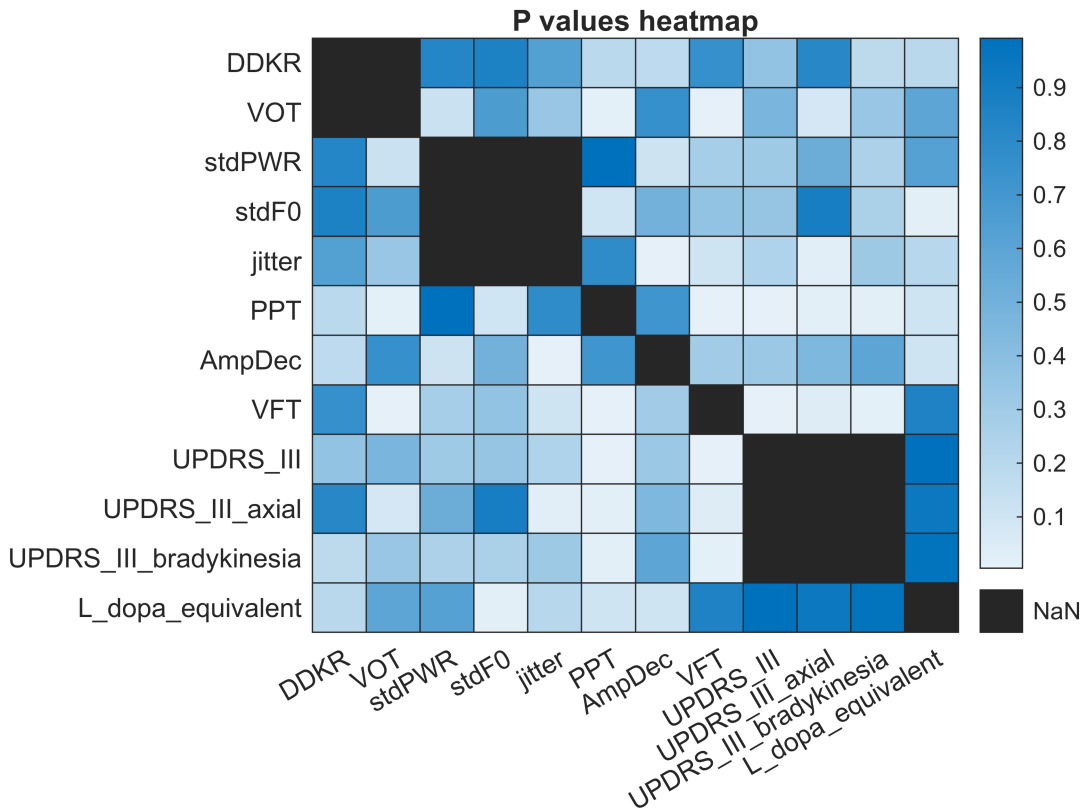

Vaše odpovědi a výsledky:

```
fprintf("r_{UPDRS III | VFT}(%.0f) = %.2f, p = %.2f\n", size(T, 1)-2, r(9, 8), p(9,
8))
```

```
r_{UPDRS III | VFT}(15) = 0.63, p = 0.01
```

```
fprintf("r_{jitter | AmpDec}(%.0f) = %.2f, p = %.2f\n", size(T, 1)-2, r(5, 7), p(5,
7))
```

```
r_{jitter | AmpDec}(15) = 0.64, p = 0.01
```

2. Regrese

- Vyberte **jednu libovolnou významnou dvojici** a vizualizujte jí ve 2D.
- Vytvořte lineární regresní model pro vybraná data. Parametry modelu (tj. v tomto případě směrnici a posun přímky) vypočítejte pomocí vztahu:

$$y = \mathbf{X} \cdot b \quad \text{kde: } y = [y_1, y_2, \dots, y_n]^T \quad \mathbf{X} = \begin{bmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix} \quad b = [b_1, b_0]^T$$

- Váš výpočet srovnejte s výstupem funkce `fit` nebo `polyfit`.
- Pomocí vypočtených regresních parametrů si vykreslete lineární regresní přímku do obrázku s vizualizovanými daty.

```
% Váš kód pro výpočet regresního modelu
data1 = T{:, "jitter"}; data2 = T{:, "AmpDec"};
scatter(data1, data2, 'x')
title("Fitting jitter x AmpDec")
xlabel("Jitter (%)"); ylabel("AmpDec (-)")
hold on
X = [data1, ones(size(data1))];
b = X\data2;

x = linspace(0, 4, 100);
y = polyval(b, x);
plot(x,y)

p = polyfit(data1, data2, 1);
y = polyval(p, x);
plot(x,y)
hold off
legend("Data", "Manual fit", "Polyfit function")
```

Vaše odpovědi a výsledky:

Můj vypočtený model má úplně stejný výstup jako model funkce polyfit.

3. Robustní regresní model

Naprogramujte výpočet robustního lineárního **model pomocí *Theil-Senovy* metody:**

1. Pro všechny unikátní dvojice bodů z vybraného datasetu vypočtěte směrnici přímky k_i, která i-tou dvojicí prochází, tj.:

   $k_i = \frac{\Delta y}{\Delta x} = \frac{y_{1,i} - y_{2,i}}{x_{1,i} - x_{2,i}}$ přes všechny unikátní dvojice bodů: $i \in \langle 1, \frac{N(N-1)}{2} \rangle$

2. Vypočtěte medián $\hat{k}$ ze všech směrnic. Výsledkem je směrnice výsledné robustní regresní přímky.

3. Vypočtěte posun robustní regresní přímky $\hat{b}$ (*bias, intercept*):

   $$b_n = y_n - \hat{k} \cdot x_n \quad \hat{b} = \text{medián } b_n \text{ přes } n \in N$$

Pomocí vypočtených parametrů **vykreslete robustní lineární regresní přímku** do stejného obrázku jako v přechozím bodě. Odpovídá výsledek očekávání?

```
% Váš kód pro výpočet robustní regresní přímky pomocí Theil-Senovy metody
k = zeros(length(data1)*(length(data2)-1)/2, 1);
N = length(data1);

c = nchoosek(1:N,2);

for i = 1:length(k)
    dx = data1(c(i, 1)) - data1(c(i,2));
    dy = data2(c(i, 1)) - data2(c(i,2));
```

```
    k(i) = dy/dx;
end

k_med = median(k);

b = zeros(N,1);


for i = 1:length(data1)
    b(i) = data2(i) - k_med * data1(i);
end

b_med = median(b,1);

coeff = [k_med, b_med];

hold on

y = polyval(coeff, x);
plot(x,y);
hold off

legend("Data", "Manual fit", "Polyfit function", 'Theil-sen',
"Location","southeast")
```

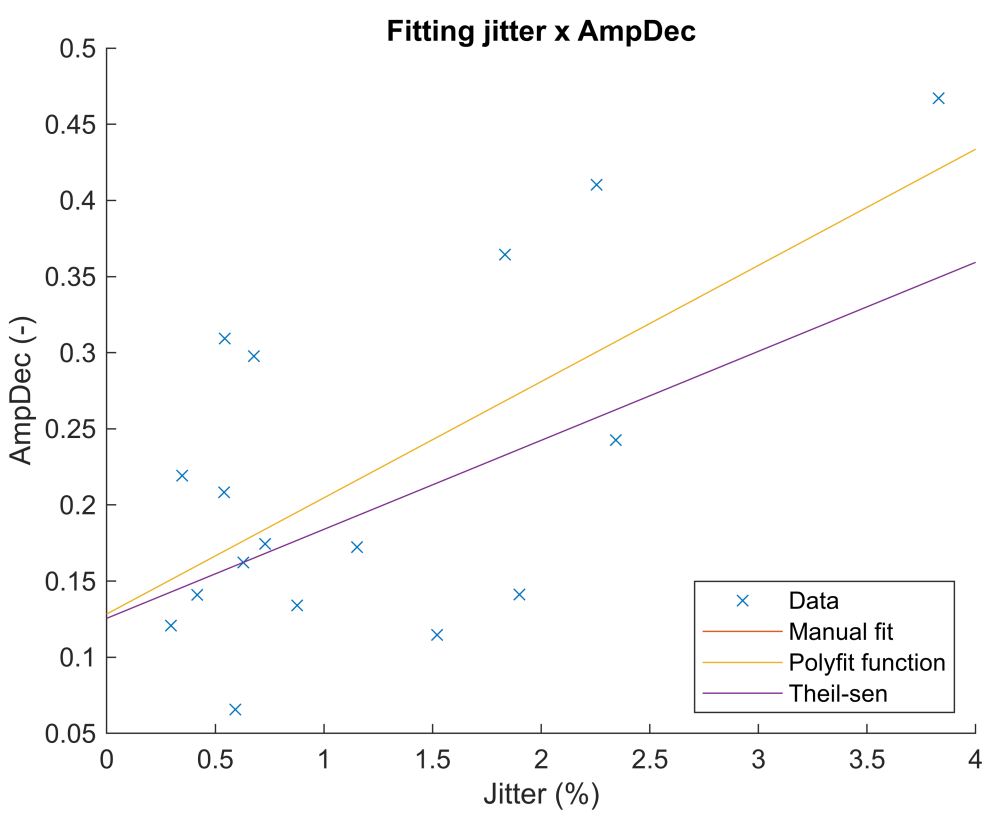

Vaše odpovědi a výsledky:

Ano, přímka je méně ovlivněna outliers.

3. Vyhodnocení kvality modelů

Analyzujte, jak dobře vámi vytvořené lineární modely popisují výchozí data. Pro oba vaše modely (klasický lineární a robustní Theil-Senův) manuálně vypočtěte následující „*goodness-of-fit*“ (GOF) veličiny:

1. Dvouvzorkový **Kolmogorov-Smirnov test** (`kstest2`): zapište hypotézy, které bude test ověřovat, výsledek korektně reportujte.
2. **SSE** (*Sum squared error*)
3. **RMSE** (*Root mean squared error*)
4. Koeficient determinace **R2**
5. **Adjusted R2**

$$\mathrm{RMSE} = \sqrt{\left(\frac{SSE}{n-m}\right)} \qquad R^2_{adj} = 1 - \frac{(1-R^2)(n-1)}{n-m-1}$$

Ve vzorcích výše je *n* je množství dat, na kterých je model založen (délka *y*) a *m* je počet parametrů, které jsou použity pro výpočet modelu (řád modelu).

Nakonec vytvořte pomocí funkce `fitlm` **vícedimenzionální lineární regresní model**, který bude mít stejnou výstupní proměnnou *y* a pro výpočet modelu použije všechny dostupné nezávislé parametry z tabulky. Nechte si vypsat výstup funkce `fitlm`, který obsahuje automaticky vypočtené *GOF* veličiny.

- Porovnejte výsledky GOF klasického a robustního modelu. Vysvětlete rozdíly mezi nimi.
- Vysvětlete rozdíly v GOF mezi modelem založeným na jednom parametru a vícedimenzionálním modelem. Jaké jsou výhody a nevýhody obou modelů?

```
% Váš kód pro výpočet kvality modelů
data2_est_lin = polyval(p, data1);
data2_est_theil = polyval(coeff, data1);

n = length(data2);
m = 2;

% 1.
[~,p_lin,ks2stat_lin] = kstest2(data2, data2_est_lin);
[~,p_theil,ks2stat_theil] = kstest2(data2, data2_est_theil);

% 2.
SSE_lin = sum(data2 - data2_est_lin)
```

```
SSE_lin = 8.6042e-16
```

```
SSE_theil = sum(data2 - data2_est_theil)
```

```
SSE_theil = 0.4140
```

```
% 3.
RMSE_lin = sqrt(SSE_lin / (n - m))
```

```
RMSE_lin = 7.5737e-09
```

```
RMSE_theil = sqrt(SSE_theil / (n - m))
```

```
RMSE_theil = 0.1661
```

```
% 4.
R2_lin = 100 * (sum((data2 - data2_est_lin) .^ 2) / sum((data2 - mean(data2)) .^ 2))
```

```
R2_lin = 58.3993
```

```
R2_theil = 100 * (sum((data2 - data2_est_theil) .^ 2) / sum((data2 -
mean(data2)) .^ 2))
```

```
R2_theil = 65.5933
```

```
% 5.
R2_adj_lin = 1 - ((1 - R2_lin) * (n - 1))/(n - m - 1)
```

```
R2_adj_lin = 66.5992
```

```
R2_adj_theil = 1 - ((1 - R2_theil) * (n - 1))/(n - m - 1)
```

```
R2_adj_theil = 74.8209
```

Vaše odpovědi a výsledky:

1. H0: odhadnutá a měřená data pochazejí ze stejných distribucí

Nezamítáme pro oba modely

Lineární regrese:

[D(32) = 0.35, p = .19, R2 = 66.5992]

Theil-sen:

[D(32) = 0.35, p = 0.19, R2 = 74.82]