Zadání Cvičení #8

Popis dat: Pracovní data jsou uložena v souboru data.csv, který je k dispozici ke stažení na Moodle stránce tohoto předmětu, ve složce příslušného cvičení. Pro načtení dat do Matlabu využijte funkce `readtable`.

Data jsou ve formátu tabulky, která obsahuje data od pacientů s Parkinsonovou nemocí (label **PD**). Tabulka obsahuje identifikační kód pacienta, pohlaví, identifikátor skupiny a řadu parametrů:

- Parametry vyhodnocené počítačem z nahrávek řeči během diadochokinetického (DDK) testu, viz Reference Novotný et al. 2014:
  - **DDKR – DDK rate**: rychlost opakování hlásek *pa-ta-ka,* jednotka *syll/s* (hlásky za sekundu).
  - **VOT – Voice Onset Time**: parametr popisující motorickou kontrolu nad délkami souhlásek, jednotka milisekundy *ms*.
- Parametry vyhodnocené pomocí programu PRAAT (Reference Boersma and Weenink 2017)
  - Z nahrávek souvislé řeči:
    - **stdPWR** – Směrodatná odchylka intenzity řeči, jednotka dB.
    - **stdF0** – Směrodatná odchylka F0, jednotka půltóny – *semitones*.
  - Z nahrávek testu prodloužené fonace hlásky "*a*":
    - **jitter** – odchylka od pravidelné periodicity chvění hlasivek při fonaci, jednotka %.
- **PPT – Purdue Pegboard Test**: manuální test, při kterém vyšetřovaný vkládá či vytahuje kolíčky do speciální desky. Hodnotí se tak zručnost, jemná i hrubá motorika, koordinace, bez jednotky.
- **AmpDec – Amplitude Decrement**: hodnocení změny maximální vzdálenosti mezi prsty během *finger tapping* úlohy, která byla zaznamenána 3D kamerovým systémem. Vyhodnocené pomocí počítače, detaily k výpočtu parametru viz Reference Krupička et al. 2020, bez jednotky.
- **VFT – Video Finger Tapping**: klinické expertní hodnocení *finger tapping* úlohy z videozáznamu (bez jednotky).
- Klinické hodnocení neurologem prostřednictvím škály UPDRS III (bez jednotky):
  - **UPDRS III**: celkové skóre z dotazníku.
  - **UPDRS III axial**: souhrnné skóre z položek, které hodnotí axiální[1] motoriku.
  - **UPDRS III bradykinesia**: souhrnné skóre z položek, které hodnotí *bradykinezii*[2].
- **L-dopa equivalent**: Síla medikace - množství *Levodopy*, které by mělo stejný výsledný efekt jako kolektivní účinek všech léků, které pacient bere za jeden den, jednotka miligramy, mg.

[1] Axiální – týkající se těch částí těla, které se nachází na svislé ose (hlava, krk, hrudník, trup, …), opak je apendikulární (týkající se končetin)

[2] *Bradykinezie* – zpomalení pohybů, snížení rozsahu a rychlosti pohybů, těžší cílená iniciace pohybů

Zadání úlohy	body
Vyhledejte lineární vztahy mezi parametry. • Pomocí korelační analýzy najděte mezi možnými dvojicemi nezávislých parametrů takové, které budou vykazovat významný lineární vztah. • Nezávislá dvojice například **není** celkové skóre dotazníku UPDRS a skóre z nějaké z jeho podsekcí. • Hranici pro určení toho, který vztah je významný, a který ne, určete buď na základě vámi zvolené hraniční hodnoty korelačního koeficientu nebo pomocí statistické významnosti korelace vůči vybrané úrovni alfa. **Uveďte, jak jste nastavili hranici významnosti a korektně reportujte výsledky korelační analýzy pro nejvýznamnější dvojice.**	1
• Vyberte **jednu libovolnou významnou dvojici** a vizualizujte jí ve 2D. • Vytvořte lineární regresní model pro vybraná data. Parametry modelu (tj. v tomto případě směrnici a posun přímky) vypočítejte pomocí vztahu: $y = \mathbf{X} \cdot b \quad \text{kde: } y = [y_1, y_2, \dots, y_n]^T \quad \mathbf{X} = \begin{bmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix} \quad b = [b_1, b_0]^T$ • Váš výpočet srovnejte s výstupem funkce `fit` nebo `polyfit`. • Pomocí vypočtených regresních parametrů si vykreslete lineární regresní přímku do obrázku s vizualizovanými daty.	0.5
Naprogramujte výpočet robustního lineárního **model pomocí *Theil-Senovy* metody:** 1. Pro všechny unikátní dvojice bodů z vybraného datasetu vypočtěte směrnici přímky k_i, která i-tou dvojicí prochází, tj.: $k_i = \frac{\Delta y}{\Delta x} = \frac{y_{1,i} - y_{2,i}}{x_{1,i} - x_{2,i}}$ přes všechny unikátní dvojice bodů: $i \in \langle 1, \frac{N(N-1)}{2} \rangle$ 2. Vypočtěte medián $\hat{k}$ ze všech směrnic. Výsledkem je směrnice výsledné robustní regresní přímky. 3. Vypočtěte posun robustní regresní přímky $\hat{b}$ (*bias, intercept*): $b_n = y_n - \hat{k} \cdot x_n \quad \hat{b} = \text{medián } b_n \text{ přes } n \in N$ Pomocí vypočtených parametrů **vykreslete robustní lineární regresní přímku** do stejného obrázku jako v přechozím bodě. Odpovídá výsledek očekávání?	1

Analyzujte, jak dobře vámi vytvořené lineární modely popisují výchozí data. Pro oba vaše modely (klasický lineární a robustní Theil-Senův) manuálně vypočtěte následující *„goodness-of-fit“* (GOF) veličiny: 1. Dvouvzorkový **Kolmogorov-Smirnov test** (`kstest2`): zapište hypotézy, které bude test ověřovat, výsledek korektně reportujte. 2. **SSE** (*Sum squared error*) 3. **RMSE** (*Root mean squared error*) 4. Koeficient determinace **R^2** 5. **Adjusted R^2** $$\mathrm{RMSE} = \sqrt{\left(\frac{SSE}{n-m}\right)} \qquad R^2_{adj} = 1 - \frac{(1-R^2)(n-1)}{n-m-1}$$ Ve vzorcích výše je *n* je množství dat, na kterých je model založen (délka *y*) a *m* je počet parametrů, které jsou použity pro výpočet modelu (řád modelu). Nakonec vytvořte pomocí funkce `fitlm` **vícedimenzionální lineární regresní model**, který bude mít stejnou výstupní proměnnou *y* a pro výpočet modelu použije všechny dostupné nezávislé parametry z tabulky. Nechte si vypsat výstup funkce `fitlm`, který obsahuje automaticky vypočtené *GOF* veličiny. • Porovnejte výsledky GOF klasického a robustního modelu. Vysvětlete rozdíly mezi nimi. • Vysvětlete rozdíly v GOF mezi modelem založeným na jednom parametru a vícedimenzionálním modelem. Jaké jsou výhody a nevýhody obou modelů?	1.5

Reference

Boersma, P. and Weenink, D. (2017). *Praat: doing phonetics by computer* [Computer program]. Version 6.0.30, retrieved 22 July 2017 from http://www.praat.org/

Novotný, M., Rusz, J., Čmejla, R., and Růžička, E. (2014). *Automatic evaluation of articulatory disorders in Parkinson's disease*. IEEE/ACM Transactions on Audio, Speech and Language Processing (TASLP), 22, 1366-1378, DOI: 10.1109/TASLP.2014.2329734

Krupička R., Krýže P., Neťuková S., Duspivová T., Klempíř O., Szabó Z., Dušek P., Šonka K., Rusz J. and Růžička E. (2020). *Instrumental analysis of finger tapping reveals a novel early biomarker of parkinsonism in idiopathic rapid eye movement sleep behaviour disorder.* Sleep Medicine, 75, 45-49, https://doi.org/10.1016/j.sleep.2020.07.019