Cvičení 9 - B2M31AEDA

Nahrání dat

Popis dat: Pracovní data jsou uložena v souboru data.csv, který je k dispozici ke stažení na Moodle stránce tohoto předmětu, ve složce příslušného cvičení. Pro načtení dat do Matlabu využijte funkce `readtable`.

```
T = readtable('data.csv','ReadVariableNames',true);
```

1. Vizualizace

```
% Váš kód pro scatter vizualizaci, popř. boxploty:
function ax = plotGroups(x, y, groups)
    labels = unique(groups);

    for i=1:length(labels)
        scatter(x(groups==labels(i)), y(groups==labels(i)))
        hold on
    end
    hold off

    ax = gca;
end

labels = unique(T.group);
groups = zeros(size(T.group));

for i=1:length(labels)
    groups(T.group == string(labels(i))) = i - 1;
end

ax = plotGroups(T{:, "stdF0"}, T{:, "stdPWR"}, groups);
legend(ax, labels)
xlabel("stdF0 (Hz)"); ylabel("stdPWR (dB)")
title("Data visualisation")
```

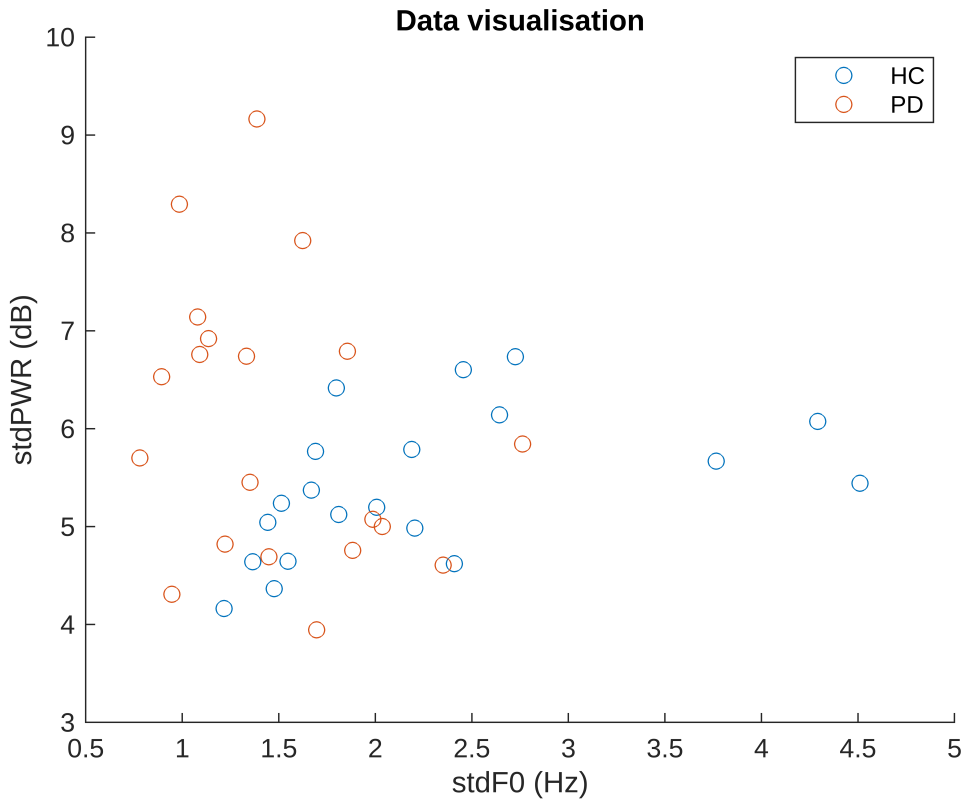

Otázky:

1. Pohledem na vaší vizualizaci zhodnoťte, jak dobře lze oddělit skupiny v 2D prostoru pomocí lineární rozhodovací hranice. Do vizualizace můžete zakreslit (od ruky) kam byste rozhodovací hranici umístili.
2. Zhodnoťte, zda není pro klasifikaci některý z parametrů nadbytečný, a zvažte, jak by se obecně daly nadbytečné (redundantní) parametry automaticky identifikovat ve vícedimenzionálních datasetech.

Odpovědi:

1. Nelze
2. Není, u obou jsou data "smíchána" a nelze je jednoduše rozdělit.

2. Klasifikace dat

Proveďte klasifikaci dat pomocí následujících metod a pro každou z nich vykreslete do obrázku s daty příslušnou rozhodovací hranici (decision boundary), abyste je mohli mezi sebou snadno vizuálně porovnat:

1. Logistická regrese (Logistic regression)

- Použijte funkce `glmfit` a `glmval`, se standardním nastavením pro binomiální rozdělení výstupní funkce.
- Pro vykreslení rozhodovací hranice můžete použít funkci `contour` na úrovni 0.5.

```
% Váš kód pro klasifikaci dat (Logistic regression)
% help glmfit
```

```
% help glmval
% help contour
X = [T.stdF0, T.stdPWR];
tic
model = glmfit(X, groups, "binomial", "Link","logit");
pLR = glmval(model,X,'logit');
LLR = double(pLR>0.5);
tLR = toc;

plotGroups(X(:,1), X(:,2),groups);
x = linspace(0,5,2);
y = (-x*model(2)+model(1))/model(3);
hold on
plot(x,y, 'black')
hold off
legend([labels; "Decision line"])
xlabel("stdF0 (Hz)"); ylabel("stdPWR (dB)")
title("Log regression")
```

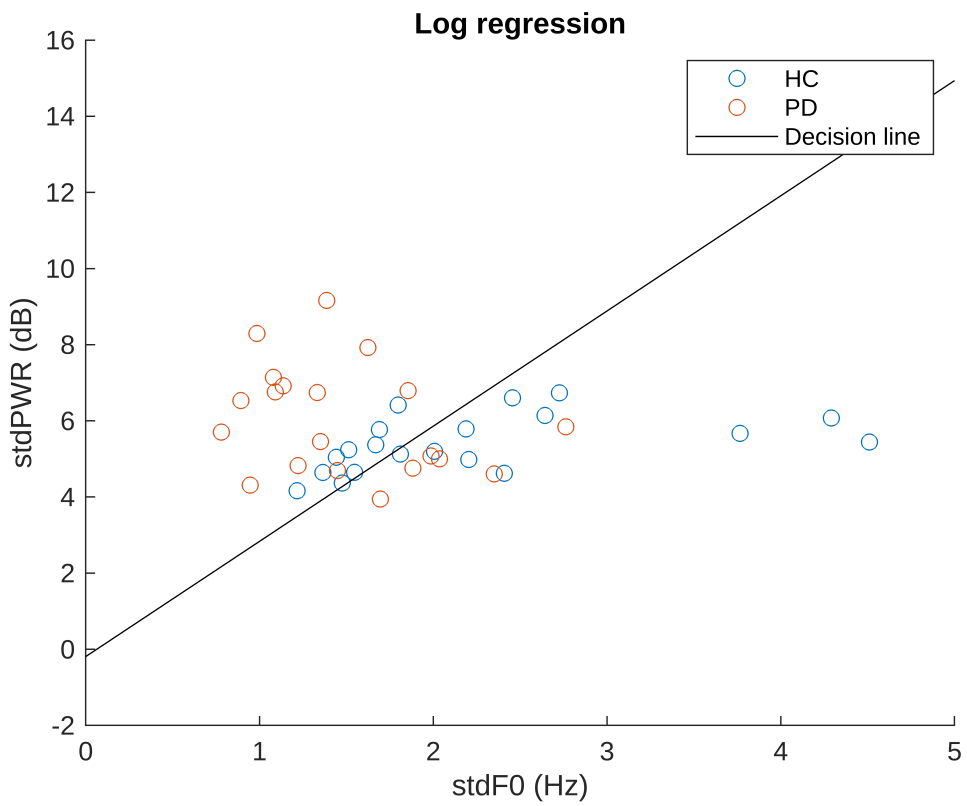

2. Lineární diskriminantní analýza (LDA)

- Pro výpočet modelu použijte funkci `fitdiscr`.
- Klasifikaci původních dat můžete provést použitím funkce `predict`.
- Rozhodovací hranici vykreslete za použití koeficientů z vypočteného modelu.

```
% Váš kód pro klasifikaci dat (LDA):
% help fitdiscr
% help predict
tic
model = fitcdiscr(X,groups,"DiscrimType","linear");
```

```
C = model.Coeffs(1,2);
b = [C.Const; C.Linear];
LLDA = predict(model, X);
tLDA = toc;

plotGroups(X(:,1), X(:,2),groups);
x = linspace(0,5,2);
y = (-x*b(2)+b(1))/b(3);
hold on
plot(x,y, 'black')
hold off
legend([labels; "Decision line"])
xlabel("stdF0 (Hz)"); ylabel("stdPWR (dB)")
title("LDA")
```

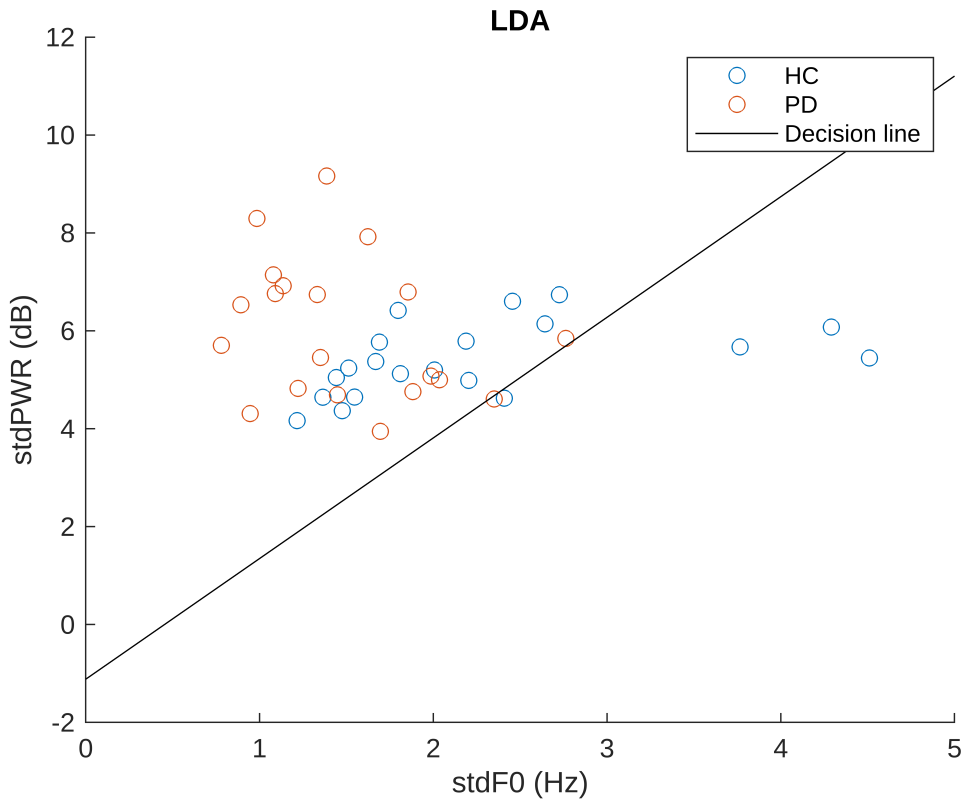

3. Support Vector Machine (SVM) s lineárním jádrem

- Výpočet SVM modelu proveďte pomocí funkce `fitcsvm`.
- Data před výpočtem SVM standardizujte! Lze standardizovat i přímo ve funkci `fitcsvm`, nicméně pokud budete kreslit rozhodovací hranice do od všech klasifikátoru do jednoho obrázku, budete muset standardizovat data ručně (abyste mohli poté de-standardizovat rozhodovací hranici).
- Vykreslete vhodným způsobem, jaké datové body určil SVM model jako *Support Vectors*.
- Koeficienty pro vykreslení rozhodovací hranice SVM modelu získáte z Matlabovské proměnné (*structure*) modelu (pole `Beta` a `Bias`).
- Klasifikaci pomocí modelu lze provést pomocí funkce `predict`, což využijete pro vyhodnocení přesnosti modelu na trénovacích datech.

```
% Váš kód pro klasifikaci dat (SVM):
% help fitcsvm
```

```
tic
Xz = zscore(X);
model = fitcsvm(Xz,groups);
b = [model.Bias; model.Beta];
LSVM = predict(model, Xz);
tSVM = toc;

plotGroups(X(:,1), X(:,2),groups);
x = linspace(0,5,2);
y = (-x*b(2)+b(1))/b(3);
hold on
plot(x,y, 'black')
hold off
legend([labels; "Decision line"])
xlabel("stdF0 (Hz)"); ylabel("stdPWR (dB)")
title("SVM")
```

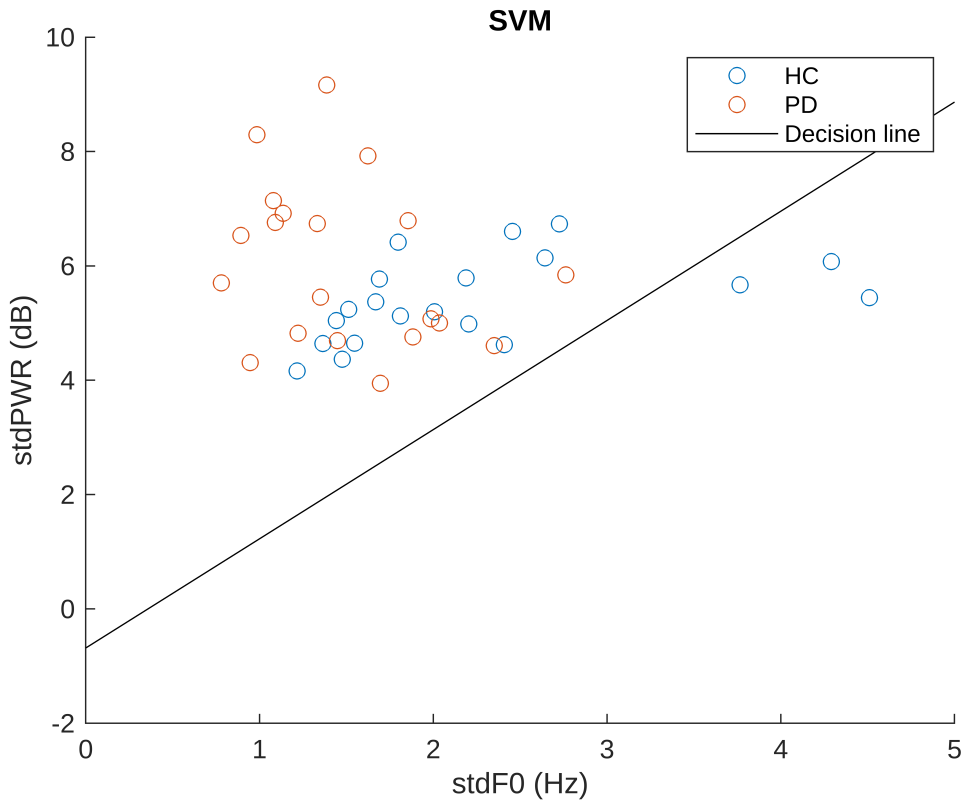

3. Porovnání klasifikací

Porovnejte jednotlivé klasifikátory z hlediska výpočetní náročnosti a přesnosti klasifikace.

- Pro měření výpočetní náročnosti využijte časoměrné funkce `tic` a `toc`.
- Pro každý z klasifikátorů vypočtěte a zobrazte matici záměn (*Confusion matrix*) – využijte funkcí `confusionmat`, resp. `confusionchart`. Přesnost klasifikace určete jako procento dat, které by model přiřadil do správné skupiny.

```
% Váš kód pro porovnání klasifikátorů
% help confusionmat
% help confusionchart
```

```
cLR = confusionmat(groups, LLR);
cLDA = confusionmat(groups, LLDA);
cSVM = confusionmat(groups, LSVM);

tiledlayout('flow');
nexttile
confusionchart(cLR,labels,'Title','Logistic
regression','Normalization','total-normalized')

nexttile
confusionchart(cLDA,labels,'Title','LDA','Normalization','total-
normalized')

nexttile
confusionchart(cSVM,labels,'Title','SVM','Normalization','total-
normalized')
```

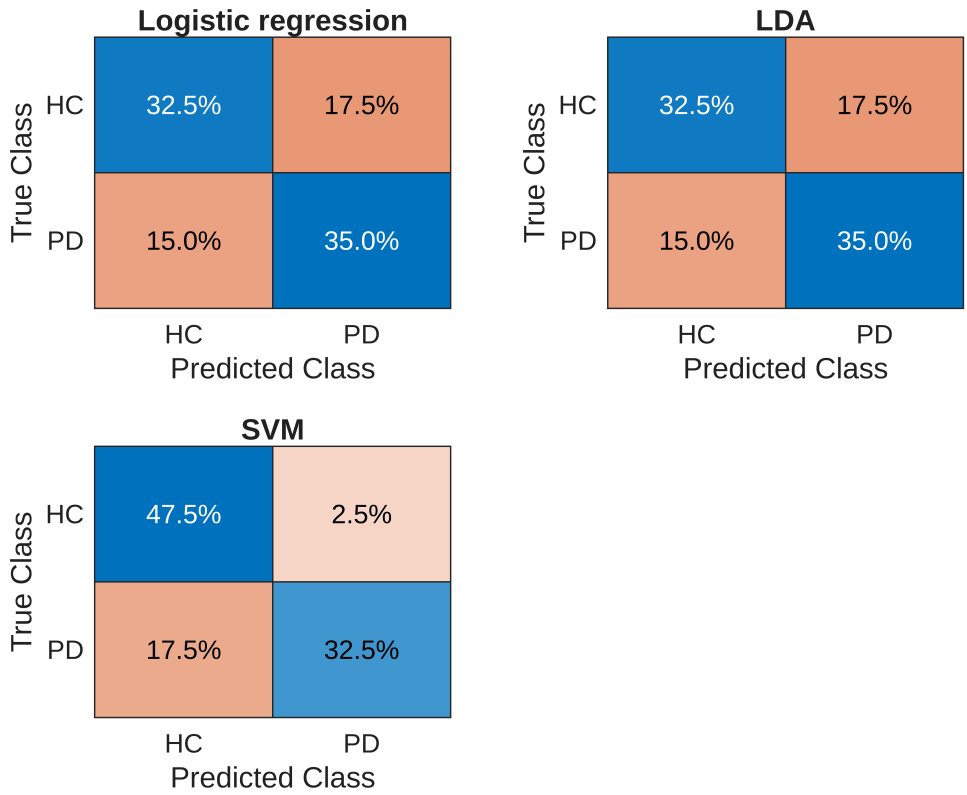

Délky výpočtů a procentuální přesnost klasifikace (pro všechny modely):

```
T = table([tLR;(cLR(1,1) + cLR(2,2))/sum(cLR, "all")*100], ...
    [tLDA;(cLDA(1,1) + cLDA(2,2))/sum(cLDA, "all")*100], ...
    [tSVM;(cSVM(1,1) + cSVM(2,2))/sum(cSVM, "all")*100], ...
    'VariableNames',["Logistic regression", "LDA", "SVM"], ...
    'RowNames',["Délka výpočtu (s)", "Přesnost klasifikace (%)"]);

disp(T)
```

```
                                Logistic regression      LDA        SVM
                                ___________________    ________   ________
```

Délka výpočtu (s)	0.025995	0.074473	0.062841
Přesnost klasifikace (%)	67.5	67.5	80

Zhodnocení a porovnání modelů:

LDA s Logistickou regresí mají stejné procento úspěšnosti, logistická regrese je přitom rychlejsí na výpočet. SVM je nejpomalejší metodou, ale má nejvyšší přesnost (o 12.5%)

Nepovinný bonus:

Implementujte manuálně algoritmus pro výpočet lineární diskriminační analýzy LDA. Pro otestování funkce použijte data uložená v souboru bonus.csv, který je dostupný ke stažení na Moodlu (proměnné jsou značeny x a y).

Odevzdejte včetně grafického zobrazení dat a rozhodovací hranice.

```
% Váš kód pro bonus:
```