B2M31DSP

Lineární prediktivní analýza LPC (*Linear Predictive Coding*)

Doc. Ing. Petr Pollák, CSc.

25. února 2025 - 12:22

Lineární prediktor, chybový signál

Lineární predikce

$$\widehat{s}[n] = -\sum_{k=1}^{p} a_k s[n-k] \; .$$

- aktuální vzorek je dán jako lineární kombinace předchozích
- prediktor je jednoduchý FIR filtr

Chybový signál

$$e[n] = s[n] - \widehat{s}[n] = s[n] + \sum_{k=1}^{p} a_k s[n-k] = \sum_{k=0}^{p} a_k s[n-k] \; .$$

- chybový signál kvantifikuje kvalitu (přesnost) výše definovaného prediktoru
- $e[n]$ je daný opět FIR filtrací signálu $s[n]$

Lineární prediktor, chybový signál

Blokové schéma prediktoru a definice chybového signálu

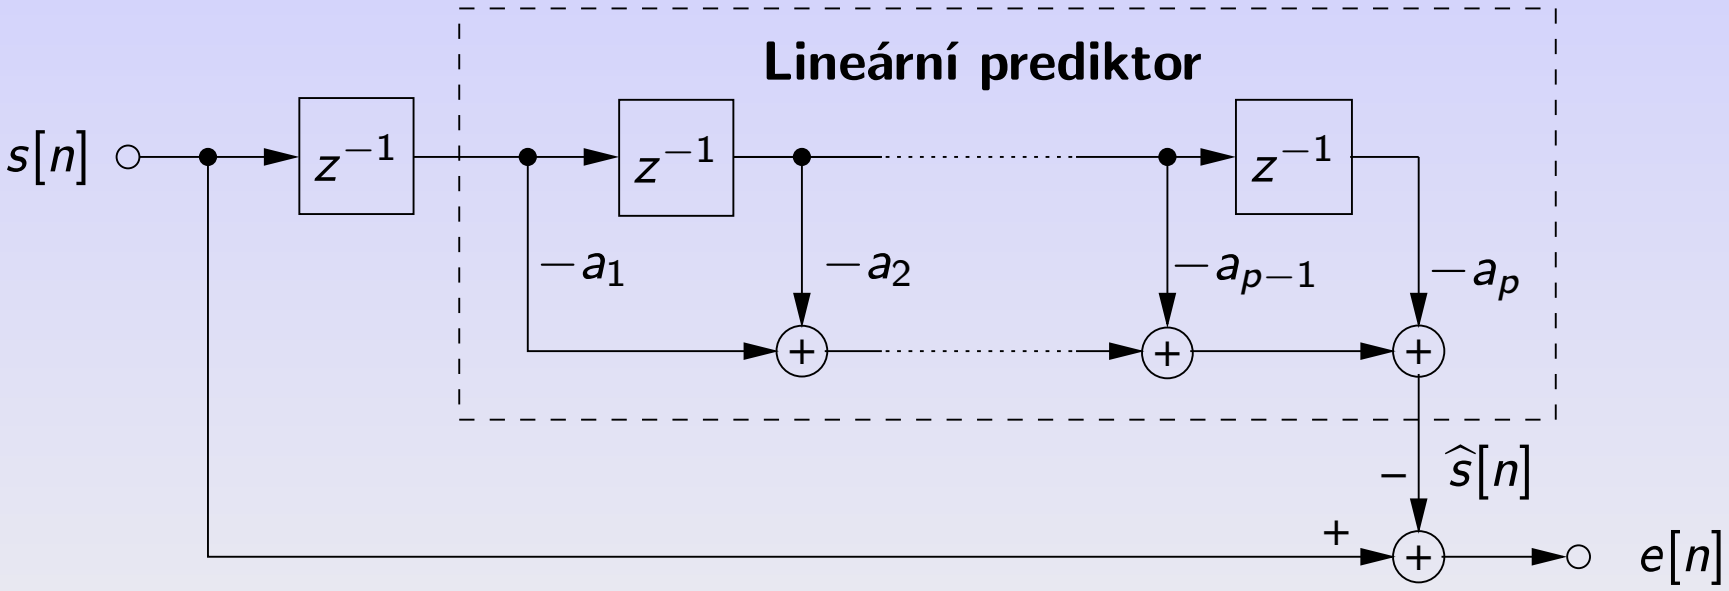

Analyzující FIR filtr

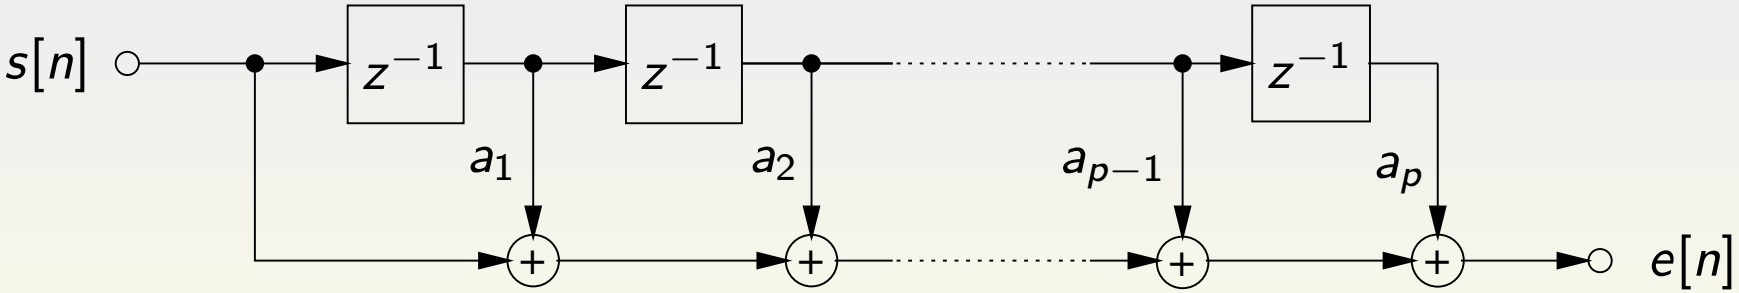

HLAVNÍ ÚKOL $\rightarrow$

- hodnoty a_k pro modelování známého signálu $s[n]$
- Lineární prediktivní analýza / kódování (LPC)

Základní princip LPC analýzy

IDEA: přesnější predikce $\rightarrow$ minimalizace chyby predikce

Možná řešení (historie používaných metod):

- metoda nejmenších čtverců (poprvé pro geodetická data)
  - Gauss (cca 1800)
- metoda střední kvadratické chyby (stac. náhodné procesy)
  - Wiener (cca 1930)
- LP pro analýzu ekonomických dat
  - Yule, Walker (cca 1930)
- LP pro kódování řeči (telekomunikace)
  - Itakura, Saito, Burg (cca 1970)

$$J = E\left[e^2[n]\right]$$

určení a_k $\rightarrow$ minimalizace J pro neznámé koeficienty a_k

$$\frac{\partial J}{\partial a_k} = 0\ , \quad \text{for} \quad k\ = 1, 2, ..., p$$

Autokorelační metoda LPC analýzy

Odvození na tabuli ....

Maticová reprezentace Yule-Walkerových rovnic

$$\begin{bmatrix} R[0] & R[1] & R[2] & \dots & R[p-1] \\ R[1] & R[0] & R[1] & & R[p-2] \\ R[2] & R[1] & R[0] & \ddots & R[p-3] \\ \vdots & & \ddots & \ddots & \vdots \\ R[p-1] & R[p-2] & R[p-3] & \dots & R[0] \end{bmatrix} \cdot \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ \vdots \\ a_p \end{bmatrix} = - \begin{bmatrix} R[1] \\ R[2] \\ \vdots \\ \vdots \\ R[p] \end{bmatrix}$$

$$\mathbf{R_s} \cdot \mathbf{a} = -\mathbf{r}_p$$

$$\Downarrow$$

ŘEŠENÍ (výpočet koeficientů a_k):

$$\mathbf{a} = -\mathbf{R_s}^{-1} \cdot \mathbf{r}_p$$

Autokorelační metoda s odhady autokorelačních koeficientů

Předpoklady pro výpočet **autokorelačních koeficientů**:

- segment signál $s[n]$ má konečnou délku N
- vzorky signálu vně analyzovaného signálu jsou rovny 0, tj.

$$s[n] = 0 \quad \text{pro} \quad n \notin < 0, N-1 > \ .$$

- Kriteriální funkce je daná následujícím vztahem,
  tj. jedná se o odhad výkonu chyby predikce v daných mezích a s výše uvedenými předpoklady

$$J = \frac{1}{N} \sum_{n=0}^{N+p-1} e^2[n]$$

Výkon chybového signálu

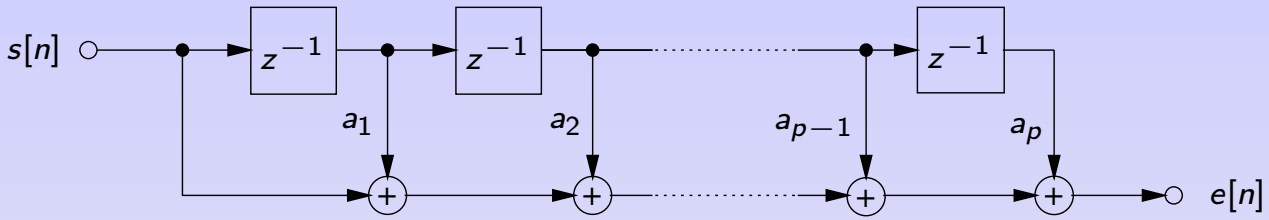

$$P_p = E\left[e^2[n]\right] = E\left[(s[n]] + a_1 s[n-1] + \ldots + a_p s[n-p])^2\right]$$

$$= E\left[(s[n] + a_1 s[n-1] + \ldots + a_p s[n-p])\,(s[n] + a_1 s[n-1] + \ldots + a_p s[n-p])\right]$$

Po roznásobení a přerovnání rovnic dostaneme:

$$\begin{aligned} P_p &= E\left[s[n](s[n] + a_1 s[n-1] + \ldots + a_p s[n-p])\right] + \\ &+ a_1 E\left[s[n-1](s[n] + a_1 s[n-1] + \ldots + a_p s[n-p])\right] + \\ &\vdots \qquad\qquad \vdots \\ &+ a_2 E\left[s[n-p](s[n] + a_1 s[n-1] + \ldots + a_p s[n-p])\right] \end{aligned}$$

$$E\left[s[n-k](s[n] + a_1 s[n-1] + \ldots + a_p s[n-p])\right] = \frac{\partial J}{\partial a_k} = 0$$

Výkon chybového signálu

Výkon chybového signálu je zjednodušen na

$$P_p = E\Big[s[n]\ \ (s[n] + a_1 s[n-1] + \ldots + a_p s[n-p])\Big]$$

Po přerovnání

$$P_p = E\Big[s[n]s[n]\Big] + a_1 E\Big[s[n]s[n-1]\Big] + \ldots + a_p E\Big[s[n]s[n-p]\Big]$$

$$\Downarrow$$

Výpočet výkonu chyby predikce pro známé koeficienty a_k

$$P_p = R[0] + a_1 R[1] + \ldots + a_p R[p]$$

$\rightarrow$ není nutno realizovat filtraci a počítat výkon přímo z chybového signálu !!

Vlastnosti autokorelační metody (Yule-Walkerovo řešení)

- Yule-Walkerovy rovnice v maticovém tvaru

$$\mathbf{R_s} \cdot \mathbf{a} = -\mathbf{r}_p$$

- matice soustavy $\mathbf{R_s}$ je ekvidiagonální a symetrická
  $\rightarrow$ Toeplitzova matice s koeficienty $R[0], \ldots, R[p-1]$

- vektor na pravé straně $\mathbf{r_p}$ obsahuje koeficienty $R[1], \ldots, R[p]$

- řešení na bázi Yule-Walkerových rovnic

$$\mathbf{a} = -\mathbf{R_s}^{-1} \cdot \mathbf{r}_p$$

  vede vždy na stabilní AR model (viz dále)

- koeficienty je možné spočítat rekurzivně pomocí Levinson-Durbinova algoritmu

- výkon chyby predikce pro známé autoregresní koeficienty je

$$P_p = R[0] + \sum_{k=1}^{p} a_k R[k]$$

Dekorelace analyzovaného signálu

Analyzující filtr

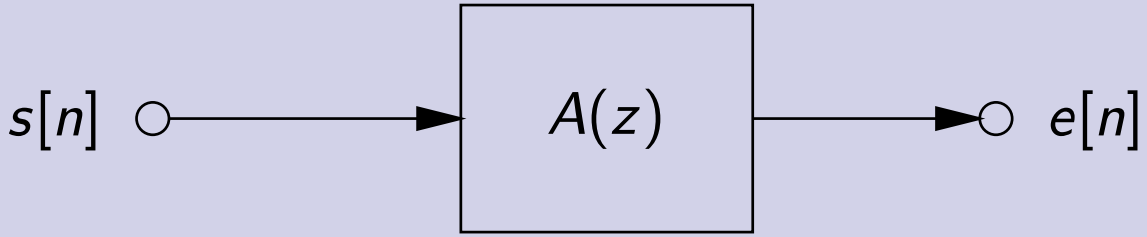

$$A(z) = \sum_{k=0}^{p} a_k z^{-k}$$

Pro optimální filtr dle Yule-Walkerových rovnic jsou vstupní analyzovaný a výstupní chybový signál nekorelované

$$E\Big[e[n] \cdot s[n-k]\Big] = 0\,, \quad \text{pro} \quad k = 1,\, 2,\, \ldots,\, p$$

Chybový signál je nekorelovaný (bílý šum, pulz, sekvence pulzů)

$E\Big[e[n] \cdot e[n-k]\Big] \doteq 0$ pro $k > 1$, (tj. krátkodobě, malá zpoždění)

Analyzující filtr $\rightarrow$ bělící filtr, dekorelující filtr

Zpětná syntéza analyzovaného signálu (modelování)

Syntéza se skutečným chybovým signálem (triviální řešení)
- syntetizující filtr je inverzní k analyzujícímu

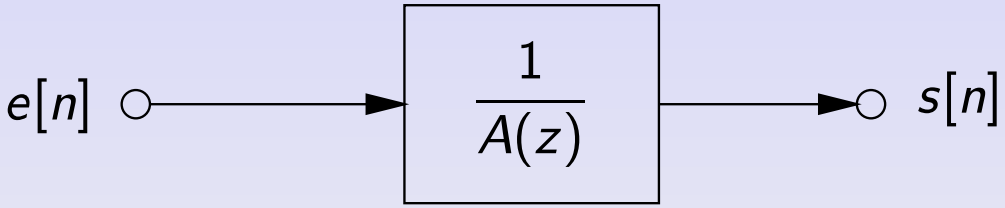

Syntéza s uměle vytvořeným buzením s jednotkovým výkonem (umělé modelování)
- G nastavuje správnou úroveň modelovaného signálu ($G = \sqrt{P_p}$)

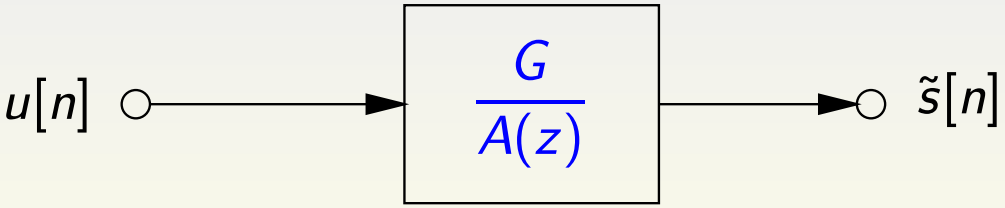

AR Modelling of Analyzed Signal
Excitation with real error signal

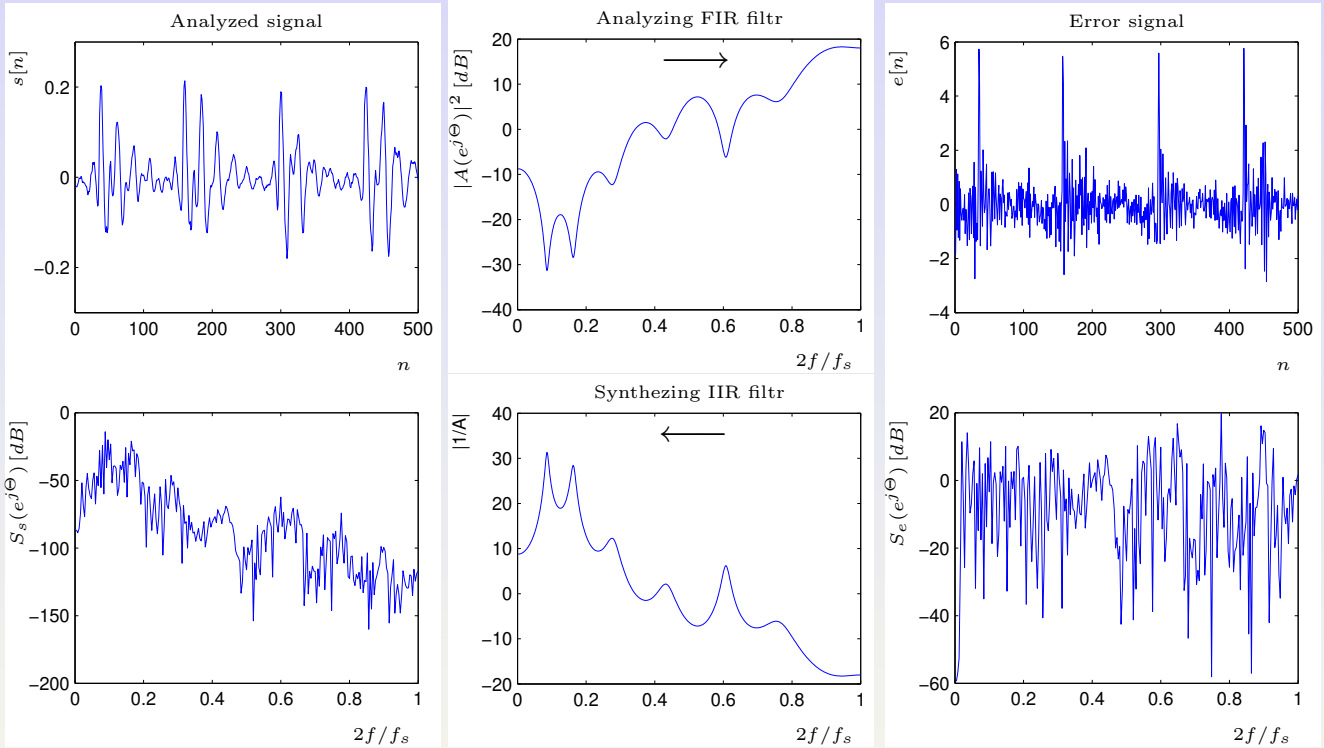

AR Modelling of Analyzed Signal
Excitation with artificial signal

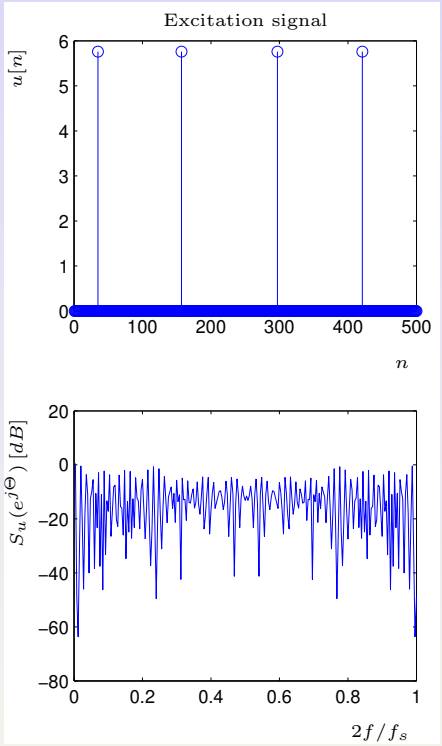

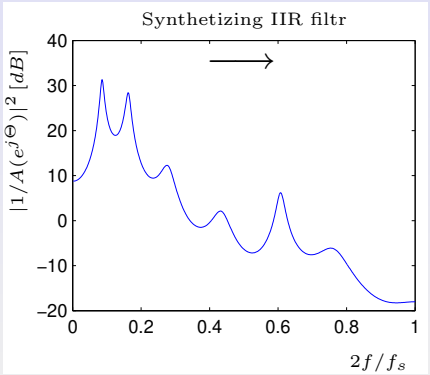

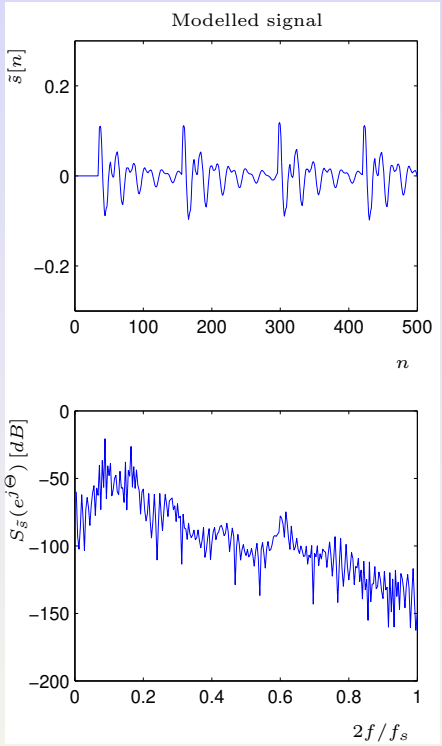

Další metody LPC analýzy

Možná řešení normálních rovnic (různá definice J):

- autokorelační metoda - nejčastěji používaná
- Levinson Durbinův algoritmus
  - rychlý výpočet z Yule-Walkerových rovnic
- kovarianční metoda (symetrická ale neekvidiagonální matice)
  - nezaručuje stabilní řešení
- Burgův algoritmus - minimalizace chyby vychází z křížové struktury

Levinson-Durbinův algoritmus

Rychlý a **rekurentní** výpočet koeficientů a_k autokorelační metodou (vychází stále z celkové chyby predikce)

Inicializace:

$$P_0 = R[0] \quad a_1^{(1)} = k_1 = -\frac{R[1]}{R[0]}$$

$$P_1 = P_0 \cdot (1 - k_1^2)$$

Výpočet pro $m = 2, 3, \ldots, p$**:**

$$a_m^{(m)} = k_m = -\frac{R[m] + \sum_{j=1}^{m-1} a_j^{(m-1)} R[m-j]}{P_{m-1}}$$

$$a_j^{(m)} = a_j^{(m-1)} + k_m a_{m-j}^{(m-1)}, \quad j = 1, 2, \ldots, m-1$$

$$P_m = P_{m-1} \cdot (1 - k_m^2)$$

Výsledek:

$$a_i = a_i^{(p)}, \quad i = 1, 2, \ldots, p$$

k_k .... koeficienty odrazu (křížová struktura filtru)
.... PARCOR koeficienty (partial correlation coefficients)

Křížová struktura při LPC analýze

Trasnverzální struktura analyzujícího FIR filtru:

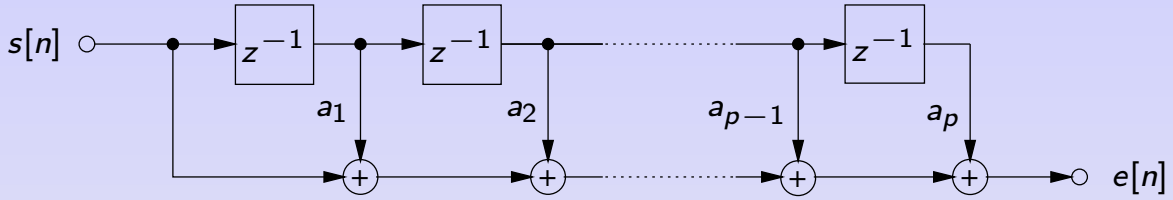

Křížová struktura analyzujícího FIR filtru:

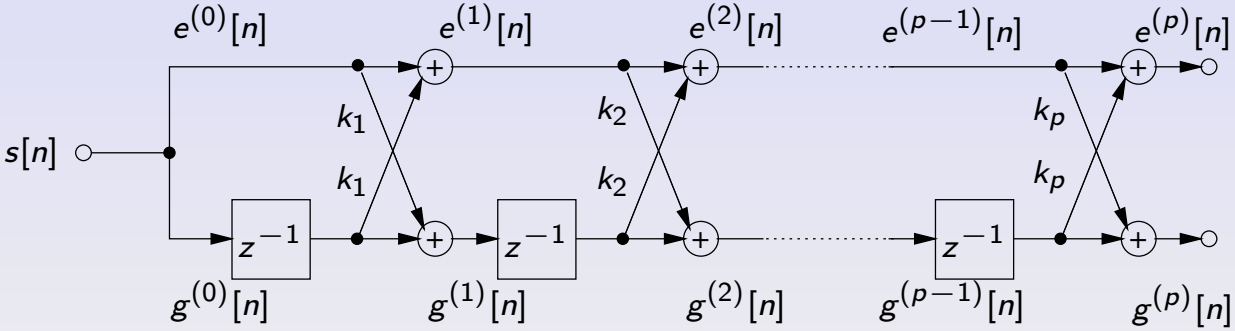

k_k ..... koeficienty odrazu, přepočet k_k vs. a_k - Levinsonova rekurze

Inicializace:

$$a_1^{(1)} = k_1$$

Výpočet pro $m = 2, 3, \ldots, p$**:**

$$a_m^{(m)} = k_m$$

$$a_j^{(m)} = a_j^{(m-1)} + k_m a_{m-j}^{(m-1)}, \quad j = 1, 2, \ldots, m-1$$

AR model - standardní a křížová struktura

Trasnverzální struktura syntetizujícího all-pole IIR filtru:

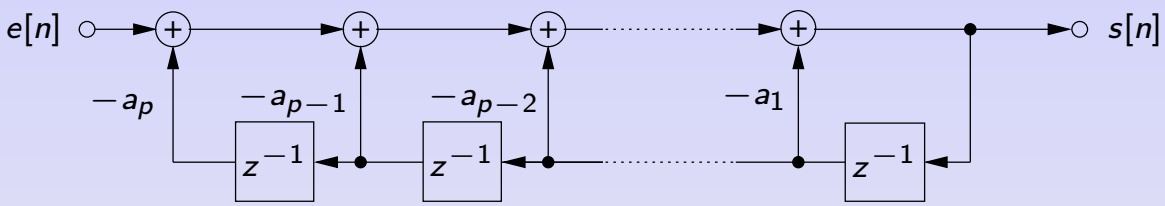

Křížová struktura syntetizujícího all-pole IIR filtru:

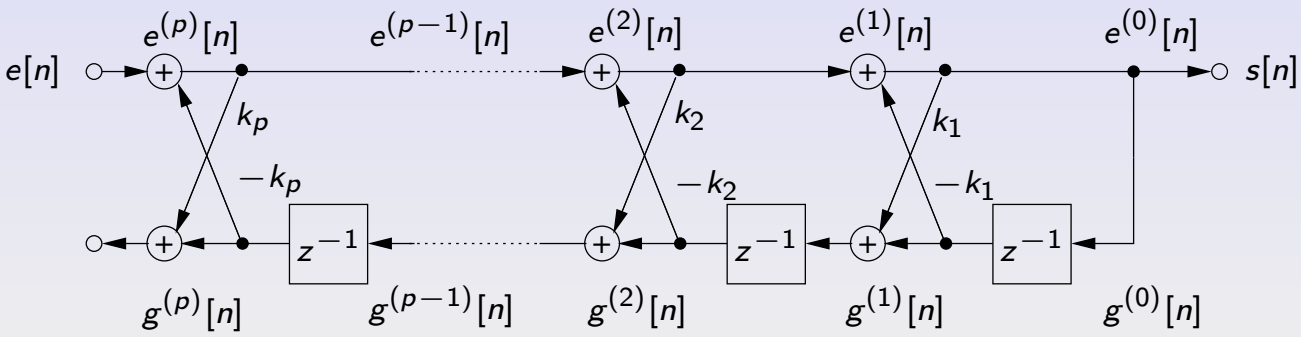

Vlastnosti koeficientů odrazu k_k :

- stabilní syntetizující filtr pro $-1 < k_k < 1$
- více robustní pro malou variabilitu signálu než a_k ($\rightarrow$ vhodné příznaky)
- vhodné pro implementace (menší problém při kvantování)
- možné interpolace
- možný **přímý výpočet koeficientů odrazu** $\rightarrow$ Burgův algoritmus

Burgův algoritmus

Minimalizační kritérium (pro každou sekci křížové struktury):

$$J_m = \frac{1}{2}\sum_{n=0}^{N-1}\left[\left(e^{(m)}[n]\right)^2 + \left(g^{(m)}[n]\right)^2\right] \qquad \text{pro } m = 1,\ 2,\ \ldots,\ p\ .$$

Inicializace: $e^{(0)}[n] = g^{(0)}[n] = s[n]$

Výpočet pro $m = 1, 2, 3, \ldots, p$**:**

$$k_m = -\frac{2\cdot\sum_{n=m}^{N-1}\left(e^{(m-1)}[n]\cdot g^{(m-1)}[n-1]\right)}{\sum_{n=m}^{N-1}\left(e^{(m-1)}[n]\right)^2 + \sum_{n=m}^{N-1}\left(g^{(m-1)}[n-1]\right)^2}$$

Vždy platí $|k_m| < 1 \quad \longrightarrow \quad$ vždy stabilní řešení

$$e^{(m)}[n] = e^{(m-1)}[n] + k_m\cdot g^{(m-1)}[n-1], \quad n = 0,\ 1,\ \ldots,\ N-m$$

$$g^{(m)}[n] = g^{(m-1)}[n-1] + k_m\cdot e^{(m-1)}[n], \quad n = 0,\ 1,\ \ldots,\ N-m$$

Další výpočty: - autoregresní koeficienty a_k - Lev. rek., viz L.-D. alg.
- výkon chyby predikce P_k - viz L.-D. alg.

LPC resp. výpočet parametrů AR modelu v MATLABu

Autokorelační metoda (Yule-Walker) :

funkce lpc ..... `[a, Ep] = lpc ( s, p ) ;`
funkce aryule ..... `[a, Ep, rc] = aryule ( s, p ) ;`

Burgův algoritmus :

funkce arburg ..... `[a, Ep, rc] = arburg ( s, p ) ;`

Vstupní a výstupní parametry uvedených funkcí :

- s ... analyzovaný signál
- p ... řád AR modelu
- a ... autoregresní koeficienty (včetně $a_0 = 1$)
- Ep ... výkon chybového signálu
- rc ... koeficienty odrazu

Aplikace LPC analýzy

Aplikační úlohy :

- LPC spektrální analýza
  - odhad vyhlazeného spektra
  - umožňuje dosáhnout lepšího frekvenčního rozlišení pro kratší signály
- identifikace AR systému
  - kódování signálu (řeč v telekomunikacích, syntéza řeči)

Spektrální vlastnosti AR modelu

Obecný popis AR modelu v Z-oblasti

$$\tilde{S}(z) = H(z) \cdot U(z)$$

Popis AR modelu ve frekvenční oblasti (PSD, výkonová spektra)

$$S_{\tilde{s}}(e^{j\Theta}) = |H(e^{j\Theta})|^2 \cdot S_u(e^{j\Theta})$$

Vlastnosti a důsledky: - $S_u(e^{j\Theta})$ je ploché
$\rightarrow$ tvar $S_{\tilde{s}}(e^{j\Theta})$ je kompletně zahrnut v AR modelu

$$\Downarrow$$

LPC spektrum (pokud $S_u(e^{j\Theta}) = 1$) $\qquad S_{\tilde{S}}(e^{j\Theta}) = |H(e^{j\Theta})|^2$

$$S_{\tilde{S}}(e^{j\Theta}) = \frac{G^2}{|A(e^{j\Theta})|^2} = \frac{G^2}{|1 + a_1 e^{-j\Theta} + a_2 e^{-j2\Theta} + \ldots + a_p e^{-jp\Theta}|^2}$$

$$\Downarrow$$

koeficienty a_k .... komprimovaná spektrální reprezentace

Srovnání LPC a DFT spektra

$$S_{\tilde{s}}(e^{j\Theta}) = |H(e^{j\Theta})|^2 \quad \approx \quad \frac{|S[k]|^2}{N}$$

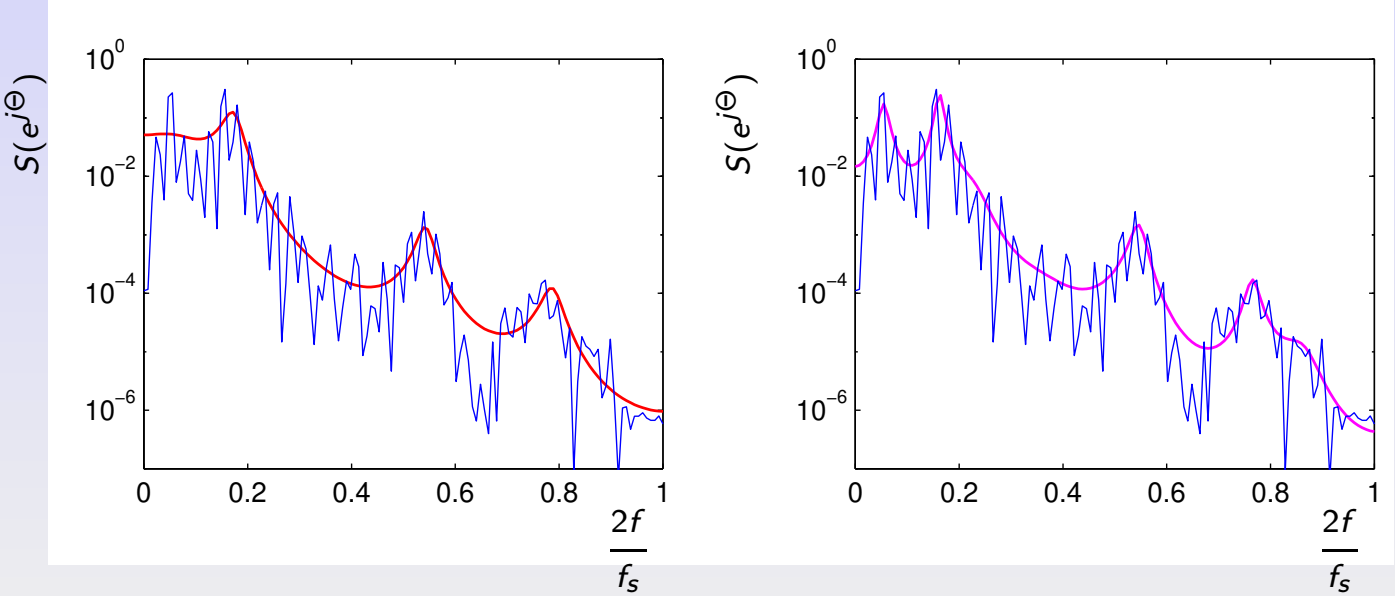

- AR model: "all-pole" filtr, modeluje pouze špičky ve spektru (rezonátory v dutinách vokálního traktu)
- obecná špička = dvojice komplexně združených pólů
- reálný pól modeluje špičku v 0 nebo $f_s/2$
- vyšší řád AR modelu = více špiček v LPC spektru
  $\rightarrow$ typické hodnoty: $p = 10$ pro $f_s = 8$ kHz, $p = 16$ pro $f_s = 16$ kHz

Srovnání vlasntostí LPC a DFT spektra

LPC spektrum:

+ pro určené parametry AR modelu, lze určit spektrum s libovolným rozlišením

+ pro kvalitnější signály lze určit parametry AR modelu z relativně velmi krátkého úseku

+ neobsahuje informaci o periodicitě ani náhodnou složku (vyhlazené spektrum, z jednoho segmentu !)

− LPC analýza je méně robustní (výsledek modelování závisí na realizaci, problém při vyšší úrovni šumu v signálu)

DFT spektrum:

+ pro signály se šumem menší vliv šumu na výpočet spektra

+ obsahuje informaci o periodicitě (dostatečně dlouhý signál)

− pro velmi krátké signály je frekvenční rozlišení dané délkou dostupných dat

− pro vyhlazený odhad je nutný delší záznam

Výpočet LPC spektra v MATLABu

Funkce freqz:

```
[H, F] = freqz ( sqrt(Ep), a, N, fs, 'whole' ) ;
```

- Ep . . . výkon chyby predikce
- a . . . autoregresní koeficienty
- N . . . počet bodů LPC spektra
- fs . . . vzorkovací kmitočet

- H . . . komplexní LPC spektrum (frekvenšní chrakteristika AR modelu)
- F . . . frekvenční body LPC spektra

Modelování řečového signálu

Signálový model produkce řeči

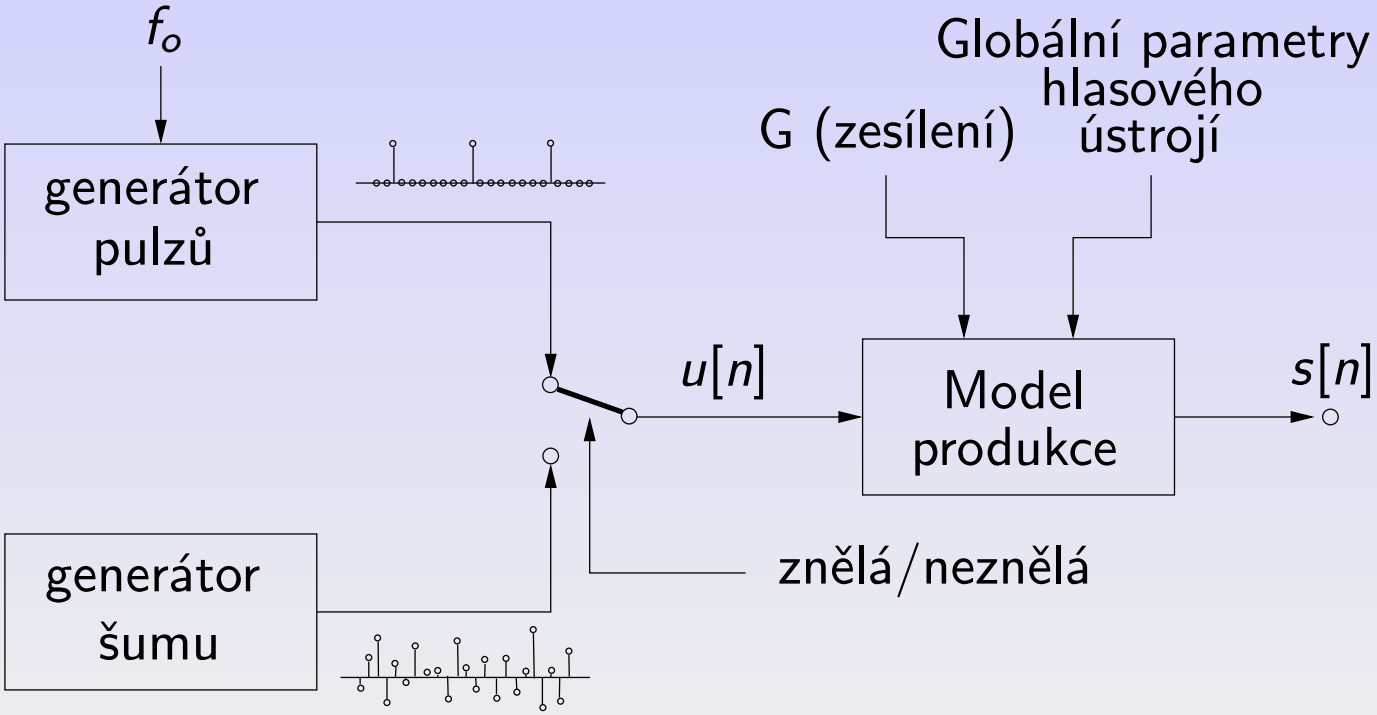

Model produkce řeči - AR model: $S(z) = H(z) \cdot U(z)$

$$H(z) = \frac{G}{1 + a_1 z^{-1} + \ldots a_p z^{-p}}$$

- nejjednodušší model
- snadná identifikace parametrů AR modelu pomocí LPC analýzy
- souvislost s rezonátory hlasového ústrojí

Základní LPC vokodér

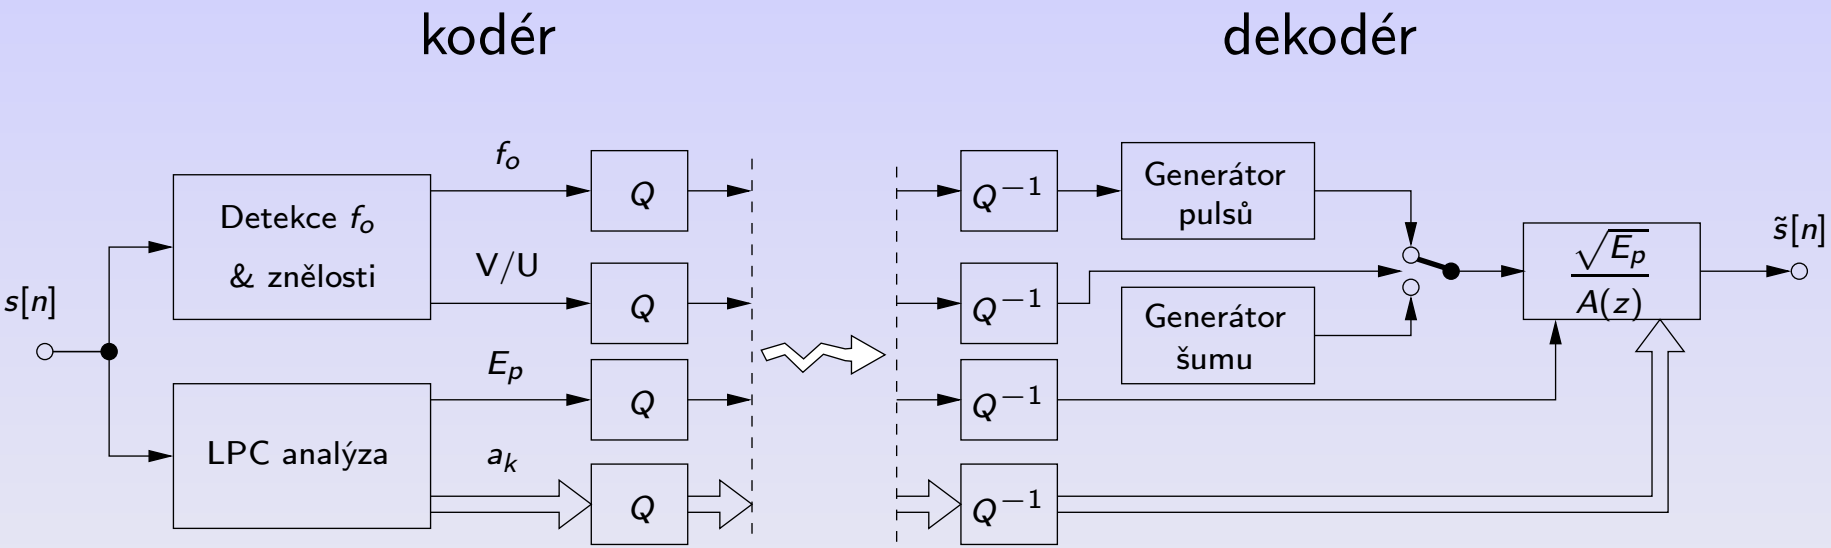

- nejjednodušší model (zejména pro buzení)
- použito US-DoD FS1015 standard:
  (parametry filtru 1800 bits/s, buzení 600 bits/s $\rightarrow$ 2,4 kbits/s)
- standardní PCM pro $f_s = 8$ kHz $\rightarrow$ 128 kbits/s
- PCM s logaritmickou kompresí pro $f_s = 8$ kHz $\rightarrow$ 64 kbits/s

- nepřirozená řeč, pro zvýšení přirozenosti $\rightarrow$ RELP, CELP